

Семинар. Матрично-векторное дифференцирование

ММП ВМК МГУ

Осень 2026

Содержание

1	Мотивация	2
2	Общее определение дифференцируемости	3
2.1	Примеры для конкретных U, V	3
3	Аппарат матрично-векторного дифференцирования	4
3.1	Правила дифференцирования	4
3.1.1	Производная суммы / разности, умножения на число	4
3.1.2	Производная произведения	5
3.1.3	Производная частного	5
3.1.4	Производная композиции	5
3.2	Табличные производные	6
3.2.1	Дифференцирование линейной функции	6
3.2.2	Дифференцирование квадратичной функции	6
3.2.3	Задача. Линейная регрессия	7
3.2.4	Дифференцирование определителя	7
3.2.5	Дифференцирование обратной матрицы	8
4	О гессиане	8
4.1	Определение	8
4.2	Способы нахождения	9
4.3	Задача. Куб второй нормы	9
5	Комплексное дифференцирование	10
5.1	Дифференцирование вещественного оператора	11
5.2	Исчисление Виртингера	11
5.3	Комплексные дифференциалы и chain-rule	13
5.4	Оптимизация	13
6	Задача. Phase retrieval: восстановление голоса по спектрограмме	13
6.1	Постановка	13
6.2	Функционал	14
6.3	Дифференцируем	14
6.4	Бонус: что это за метод	15

1 Мотивация

Представим, что нам удалось предложить для решения некоторой задачи модель машинного обучения. После этого требуется найти такие ее параметры, которые бы минимизировали некоторую функцию, имеющую смысл потерь:

$$\mathcal{L}(X, \theta) \rightarrow \min_{\theta}$$

При ее решении (аналитическом или численном) почти наверное возникает потребность в нахождении градиента $\nabla_{\theta}\mathcal{L}$ функции. Какие существуют варианты решения этой задачи?

Из курса математического анализа нам известно, что компоненты вектора градиента совпадают с частными производными по соответствующим переменным:

$$(\nabla_{\theta}\mathcal{L})_i = \frac{\partial \mathcal{L}}{\partial \theta_i}$$

Попробуем, используя данный подход, получить выражение для градиента следующей функции векторного аргумента:

$$f(x_1, \dots, x_n) = f(x) = \langle Ax, x \rangle, \quad A \in \mathbb{R}^{n \times n}$$

Для этого найдем выражение для функции f через компоненты аргумента:

$$f(x_1, \dots, x_n) = \sum_{i,j} a_{ij}x_i x_j$$

Продифференцируем его по переменной x_k :

$$\begin{aligned} \frac{\partial f}{\partial x_k} &= \frac{\partial}{\partial x_k} \sum_{i,j} a_{ij}x_i x_j \\ &= \frac{\partial}{\partial x_k} \left[\sum_{i \neq k} a_{ik}x_i x_k + \sum_{j \neq k} a_{kj}x_k x_j + a_{kk}x_k^2 + \sum_{i \neq k, j \neq k} a_{ij}x_i x_j \right] \\ &= \sum_{i \neq k} a_{ik}x_i + \sum_{j \neq k} a_{kj}x_j + 2a_{kk}x_k \\ &= \left(\sum_{i \neq k} a_{ik}x_i + a_{kk}x_k \right) + \left(\sum_{j \neq k} a_{kj}x_j + a_{kk}x_k \right) \\ &= \sum_i a_{ik}x_i + \sum_j a_{kj}x_j = (A^{\top}x)_k + (Ax)_k = ([A + A^{\top}]x)_k \end{aligned}$$

Отсюда мы получаем следующее выражение для градиента:

$$\nabla f = (A + A^{\top})x$$

Обратим внимание на то, что выражения и для функции, и для градиента имеют очень простой вид в матричной форме, а при работе на уровне координат выражения получались сложнее.

Этот пример наталкивает нас на идею развития другого, более общего аппарата дифференцирования, который позволяет «общаться» с градиентом на более высоком уровне и, как следствие, получать для его вычисления выражения в терминах матрично-векторных операций, удобных для аналитической работы и вычислительно эффективных.

2 Общее определение дифференцируемости

Попробуем естественным образом обобщить понятие производной функции одной переменной. Для этого вспомним его.

Определение. Говорят, что функция $f: B(a) \rightarrow \mathbb{R}$ дифференцируема в точке $a \in \mathbb{R}$, если ее приращение в достаточно малой окрестности с точностью до членов более высокого порядка малости описывается линейной функцией приращения аргумента:

$$f(a+h) - f(a) = Ah + \bar{o}(h), \quad h \rightarrow 0$$

Посмотрим на A не как на число, а как на линейный оператор $L_A(h) = Ah$. По аналогии продолжим определение на более абстрактные пространства. Мы бы хотели говорить, что отображение дифференцируемо в точке, если его приращение линейно зависит от приращения аргумента (для этого потребуем линейности пространства) с точностью до членов большего порядка малости (для этого — нормированности). Как итог, формулируем:

Определение. Пусть U, V — линейные нормированные пространства. Говорят, что функция $f: B(x) \subset U \rightarrow V$ дифференцируема в точке $x \in U$, если

$$f(x+h) - f(x) = Lh + \bar{o}(\|h\|),$$

где $L: U \rightarrow V$ — линейный оператор, называемый **первой производной** функции, $\bar{o}$ понимается в смысле нормированных пространств. Оператор L обозначается $df(x)$, а его действие на приращение — $df(x)[h]$.

Замечание 1. Существуют и другие обозначения для первой производной, в том числе иногда приращение для однородности записи обозначают за dx . Иногда приращение опускают для компактности записей, мы тоже будем так делать при решении задач, в общем случае важно помнить, что первая производная — это оператор, что подчеркивается ее действием на аргумент. Так, формально то, что первая производная функции x^2 — это $2x$, следует записать так:

$$d(x^2)[dx] = 2x dx,$$

однако при решении задач мы пишем

$$d(x^2) = 2x dx$$

Замечание 2. Существуют и другие **названия** для первой производной: производная по Фреше, дифференциал, дифференциальный оператор. Все они «об одном и том же», но в конкретной области математики / размерности могут обозначать чуть разные вещи. Сегодня наша цель — познакомиться с двумя основными объектами: линейным оператором, отвечающим за линейное приближение, и градиентом. Иногда понятие первой производной будет заменяться синонимичными понятиями.

2.1 Примеры для конкретных U, V

Для лучшего понимания определения рассмотрим его для нескольких конкретных пространств U и V .

- $U = V = \mathbb{R}$. Определение совпадает с определением дифференцируемости одномерной функции действительного аргумента. $df(x)$ — число, dx — число.

- $U = \mathbb{R}^n$, $V = \mathbb{R}$. Определение совпадает с определением дифференцируемости одномерной функции многих переменных / векторного аргумента, рассмотренным в курсе математического анализа. В этом случае $df(x)$ — линейный функционал, действующий на dx — вектор. Линейный функционал во всяком конечномерном пространстве представим скалярным произведением на некоторый его элемент, называемый **градиентом**:

$$df(x)[dx] = \langle \nabla f(x), dx \rangle = \nabla f(x)^\top dx = dx^\top \nabla f(x)$$

Итак, ∇f в этом случае вектор.

- $U = \mathbb{R}^{n \times m}$, $V = \mathbb{R}$. Учитывая изоморфность пространств $\mathbb{R}^{n \times m}$ и $\mathbb{R}^{nm}$, данный случай ничем не отличается от предыдущего, просто переменные организованы не в вектор, а в матрицу, из-за чего скалярное произведение принимает другой вид ($df(X)$ — все еще линейный функционал, уже действующий на dX — матрицу):

$$\begin{aligned} df(X)[dX] &= \langle \nabla f(X), dX \rangle = \text{tr}[dX^\top \nabla f(X)] \\ &= \text{tr}[\nabla f(X)^\top dX], \end{aligned}$$

где $\text{tr}[\cdot]$ — след матрицы.

- $U = \mathbb{R}^n$, $V = \mathbb{R}^m$. Вектор-функцию с образами в $\mathbb{R}^m$ в контексте дифференцируемости можно рассматривать как набор из m одномерных функций. Производная $df(x)$ — линейный оператор $\mathbb{R}^n \rightarrow \mathbb{R}^m$ — представляется в виде $m \times n$ -матрицы J_f , называемой **якобианом**:

$$df(x)[dx] = J_f(x)dx$$

3 Аппарат матрично-векторного дифференцирования

Как мы будем действовать, если нам нужно продифференцировать одномерную функцию действительного аргумента? Конечно, мы не будем делать это по определению, а воспользуемся правилами дифференцирования и таблицей стандартных производных. Если нам удастся получить их аналоги в матрично-векторном случае, то мы решим задачу аналитического вычисления градиента, превратив это занятие в такое же ремесло, как и дифференцирование функции одной переменной.

3.1 Правила дифференцирования

Еще немного «посидим» в абстракции и выведем правила дифференцирования, аналогичные тем, которые мы получали в 1-м семестре в курсе математического анализа.

3.1.1 Производная суммы / разности, умножения на число

Первая производная линейна по функции, от которой она берется:

$$d(\alpha f + \beta g)(x)[h] = \alpha df(x)[h] + \beta dg(x)[h]$$

Не будем на этом подробно останавливаться, желающим еще раз себя проверить в понимании определения остается в качестве упражнения.

3.1.2 Производная произведения

Правило дифференцирования произведения аналогично одномерному случаю. Идея вывода та же: применить известный прием «добавить-вычесть». Важно обратить внимание на то, что, вообще говоря, непонятно, о какой операции умножения идет речь. Дальнейшие рассуждения проведены при достаточно скромных ограничениях на ее структуру, что делает их верными, например, для произведения матриц (помним про отсутствие его коммутативности) и для скалярного произведения.

$$\begin{aligned} & f(x+h)g(x+h) - f(x)g(x) \\ &= f(x+h)g(x+h) - f(x)g(x+h) \\ & \quad + f(x)g(x+h) - f(x)g(x) \\ &= (f(x+h) - f(x))g(x+h) + f(x)(g(x+h) - g(x)) \end{aligned}$$

Теперь расписываем выражения в скобках по определению первой производной, появляются $df(x)[h]$ и $dg(x)[h]$ соответственно.

$$= (df(x)[h] + \bar{o}(\|h\|))(g(x) + \bar{o}(1)) + f(x)(dg(x)[h] + \bar{o}(\|h\|))$$

Выделяем главную линейную часть:

$$= df(x)[h]g(x) + f(x)dg(x)[h] + \bar{o}(\|h\|)$$

3.1.3 Производная частного

Выводится для случая деления на скалярную функцию из правила дифференцирования произведения:

$$\begin{aligned} d\left(\frac{f}{\varphi}\right)(x)[h] &= d\left(f \cdot \frac{1}{\varphi}\right)(x)[h] \\ &= df(x)[h]\frac{1}{\varphi(x)} - f(x)\frac{1}{\varphi^2(x)}d\varphi(x)[h] \\ &= \frac{df(x)[h]\varphi(x) - f(x)d\varphi(x)[h]}{\varphi^2(x)} \end{aligned}$$

3.1.4 Производная композиции

Остался последний и, возможно, самый мощный инструмент при дифференцировании — правило производной композиции. Итак, пусть $g: U \rightarrow V$ — дифференцируема в точке x , $f: V \rightarrow W$ — дифференцируема в точке $g(x)$, тогда первая производная функции $f \circ g: U \rightarrow W$ в точке x имеет следующий вид:

$$d(f \circ g)(x)[h] = df(g(x))[dg(x)[h]]$$

Легко запоминается, ведь по записи почти в точности повторяет аналогичный результат в одномерном случае:

$$(f \circ g)'(x) = f'(g(x))g'(x)$$

3.2 Табличные производные

Перед выводом таблицы производных укажем два полезных способа самопроверки при выполнении операций матрично-векторного дифференцирования.

1. **Проверяйте размерность результата.** Например, при дифференцировании функции $\mathbb{R}^n \rightarrow \mathbb{R}$ в качестве градиента должен получиться вектор из $\mathbb{R}^n$, не вектор другой размерности, не матрица и не число.
2. **Проверяйте результат на одномерном случае.** Если размерность градиента сошлась, то полезно бывает посмотреть на то, совпадают ли полученная формула и производная изначальной функции в случае $n = 1$.

3.2.1 Дифференцирование линейной функции

Найдем, чему равна производная линейной функции. Итак, пусть f — линейное отображение, тогда:

$$f(x+h) - f(x) = f(x) + f(h) - f(x) = f(h) = f(h) + 0,$$

т.е. первая производная линейной функции действует на приращение аргумента, как и сама функция. Примеры:

$$\begin{aligned} d\langle c, x \rangle &= \langle c, dx \rangle \\ d \operatorname{tr}[AXB] &= \operatorname{tr}[AdX B] \end{aligned}$$

3.2.2 Дифференцирование квадратичной функции

Найдем, чему равна производная квадратичной функции

$$f(x) = \langle Ax, x \rangle$$

Распишем приращение

$$\begin{aligned} &\langle A(x+h), x+h \rangle - \langle Ax, x \rangle \\ &= \langle Ax + Ah, x+h \rangle - \langle Ax, x \rangle \\ &= \langle Ax, h \rangle + \langle Ah, x \rangle + \langle Ah, h \rangle \\ &= \langle Ax, h \rangle + \langle h, A^\top x \rangle + \langle Ah, h \rangle \\ &= \langle Ax, h \rangle + \langle A^\top x, h \rangle + \langle Ah, h \rangle \\ &= \langle (A + A^\top)x, h \rangle + \langle Ah, h \rangle \end{aligned}$$

Если мы покажем, что второе слагаемое является $\bar{o}$ от $\|h\|$, то мы по определению сможем утверждать, что

$$df(x) = d\langle Ax, x \rangle = \langle (A + A^\top)x, dx \rangle$$

Действительно, по неравенству Коши-Буняковского и определению нормы:

$$|\langle Ah, h \rangle| \leq \|Ah\| \|h\| \leq \|A\| \|h\|^2 = \bar{o}(\|h\|)$$

Самопроверка: градиент $(A + A^\top)x$ — результат произведения квадратной матрицы на вектор, значит вектор той же размерности; в одномерном случае $f(x) = ax^2$, ее производная $f'(x) = 2ax = (a + a)x$.

3.2.3 Задача. Линейная регрессия

На предыдущем семинаре Вы подробно изучали линейную регрессию. Вы получили выражение для аналитического решения, используя сведения о псевдорешениях из линейной алгебры. Сейчас у нас достаточно результатов, чтобы получить этот результат с помощью средств матрично-векторного дифференцирования. Итак, рассмотрим функцию потерь для линейной регрессии с ℓ_2 -регуляризацией:

$$\mathcal{L}(w) = \|Xw - y\|^2 + \lambda \|w\|^2$$

Представляя квадрат второй нормы как скалярный квадрат, имеем следующее:

$$d\mathcal{L} = d\langle Xw - y, Xw - y \rangle + \lambda d\langle w, w \rangle$$

Раскрываем скалярный квадрат в первом слагаемом

$$= d\langle Xw, Xw \rangle - 2d\langle Xw, y \rangle + d\langle y, y \rangle + \lambda d\langle w, w \rangle$$

«Подгоняем» переносом через транспонирование функционалы к ранее вычисленным табличным:

$$= d\langle X^\top Xw, w \rangle - 2d\langle X^\top y, w \rangle + \lambda d\langle Iw, w \rangle$$

Применяем формулы:

$$\begin{aligned} &= 2\langle X^\top Xw, dw \rangle - 2\langle X^\top y, dw \rangle + 2\lambda \langle w, dw \rangle \\ &= \langle 2(X^\top X + \lambda I)w - 2X^\top y, dw \rangle \end{aligned}$$

Как итог

$$\nabla \mathcal{L}(w) = 2(X^\top X + \lambda I)w - 2X^\top y$$

Приравнивая его к нулю, получаем изученное в рамках семинара по линейной регрессии аналитическое решение:

$$w_{\text{opt}} = (X^\top X + \lambda I)^{-1} X^\top y$$

Самопроверка: полученный градиент есть разность двух произведений матрицы на вектор — тоже вектор; в одномерном случае функция потерь линейной регрессии имеет вид

$$l(w) = (xw - y)^2 + \lambda w^2$$

Ее производная:

$$l'(w) = 2(xw - y)x + 2\lambda w = 2(x \cdot x + \lambda \cdot 1)w - 2xy$$

3.2.4 Дифференцирование определителя

Мы уже упоминали то, что переменные могут быть собраны в матрицу. Попробуем продифференцировать функцию матричного аргумента.

В качестве примера рассмотрим определитель матрицы. Найдём его производную через поэлементное рассмотрение. Будем рассматривать случай обратимых X . Итак, разложим определитель матрицы $X = (x_{ij})$ по теореме Лапласа по i -й строке:

$$\det X = \sum_j x_{ij} A_{ij},$$

где A_{ij} — соответствующее алгебраическое дополнение. Возьмем частную производную по x_{ij} :

$$\frac{\partial \det X}{\partial x_{ij}} = A_{ij}$$

Для завершения вывода осталось вспомнить, как через алгебраические дополнения можно выразить элементы обратной матрицы:

$$(X^{-1})_{ij} = \frac{A_{ji}}{\det X} \Rightarrow A_{ij} = \det X (X^{-1})_{ji} = \det X (X^{-\top})_{ij}$$

Как итог получаем выражение для производной определителя:

$$\frac{\partial \det X}{\partial x_{ij}} = \det X (X^{-\top})_{ij} \Rightarrow d \det X = \det X \langle X^{-\top}, dX \rangle$$

3.2.5 Дифференцирование обратной матрицы

В курсе математического анализа мы часто дифференцировали выражения, из которых интересующая нас функция не выражалась явно, с целью нахождения ее производной. Воспользуемся аналогичным трюком для нахождения первой производной обратной матрицы:

$$d(X X^{-1}) = dI$$

$$dX X^{-1} + X dX^{-1} = 0$$

$$dX^{-1} = -X^{-1} dX X^{-1}$$

4 О гессиане

В курсе математического анализа понятие дифференцируемости в точке обобщалось на понятие производной функции, которое в свою очередь позволяло определить производные произвольных порядков, оказавшиеся крайне полезным инструментом как для анализа, так и для создания численных методов.

Посмотрим на эти идеи в матрично-векторном случае. Остановимся на второй производной. Производные порядков выше второго почти не используются на практике, к тому же аналитически представляются сильно сложнее младших братьев.

4.1 Определение

Определение строится на следующем наблюдении: *«Вторая производная — это первая производная первой производной»*. Суждение, безусловно, философское, однако, кроме шуток, оно помогает не путаться с тем, кто есть кто.

Итак, первая производная функции f — это линейный функционал $df(x)[h]$, зависящий от точки x , в которой берется производная, действующий на приращение h . Такие функционалы сами по себе образуют линейное пространство (его называют **сопряженным**), а значит, если $df[\cdot]$ определен(а) в некоторой окрестности точки x , то в ней мы можем рассмотреть отображение: $x \mapsto df(x)[\cdot]$.

Теперь предположим, что оно имеет первую производную. Запишем это:

$$df(x+h)[\cdot] - df(x)[\cdot] = d(df[\cdot])(x)[h] + \bar{o}(\|h\|)[\cdot]$$

Использование значка $[\cdot]$ еще раз обращает внимание на то, что df — это оператор. В дальнейшем мы будем записывать это по-другому, вводя «как бы» два приращения: h_2 имеет смысл приращения с точки зрения дифференцирования, h_1 — приращения, на котором определены первые производные $df(x)$:

$$df(x + h_2)[h_1] - df(x)[h_1] = d^2f(x)[h_1, h_2] + \bar{o}(\|h_2\|)[h_1]$$

Теперь подумаем над тем, как выглядит вторая производная в «хороших» случаях, например, когда $U = \mathbb{R}^n$, $V = \mathbb{R}$. Мы знаем, что в таком случае первая производная есть скалярное произведение с вектором градиента:

$$\begin{aligned} df(x + h_2)[h_1] - df(x)[h_1] &= \langle \nabla f(x + h_2), h_1 \rangle - \langle \nabla f(x), h_1 \rangle \\ &= \langle \nabla f(x + h_2) - \nabla f(x), h_1 \rangle \end{aligned}$$

Градиент — это отображение $\mathbb{R}^n \rightarrow \mathbb{R}^n$, поэтому его первая производная — умножение на некоторую матрицу, которая как раз и называется **гессианом**, ее элементы — вторые частные производные функции f :

$$= \langle \nabla^2 f(x) h_2, h_1 \rangle + \langle \bar{o}(\|h_2\|), h_1 \rangle$$

4.2 Способы нахождения

Рецепт поиска гессиана при найденном градиенте заключается в следующем: объявить ранее использованный dx за dx_1 и, пользуясь ранее выведенными правилами, продифференцировать градиент, обозначая новое приращение за dx_2 . Далее следует привести полученное выражение к каноническому виду

$$d^2f = \langle \nabla^2 f dx_2, dx_1 \rangle,$$

откуда и получить выражение для гессиана. Решим несколько задач по описанному алгоритму.

4.3 Задача. Куб второй нормы

Найдем градиент и гессиан следующей функции:

$$f(x) = \frac{1}{3} \|x\|^3$$

Для этого представим ее в следующем виде:

$$f(x) = \frac{1}{3} \langle x, x \rangle^{\frac{3}{2}}$$

Воспользуемся правилами дифференцирования композиции и квадратичной функции для нахождения градиента:

$$df = \frac{1}{2} \|x\| d\langle x, x \rangle = \|x\| \langle x, dx \rangle$$

Приступим к поиску гессиана

$$d^2f = d(\|x\| \langle x, dx_1 \rangle) = d\|x\| \langle x, dx_1 \rangle + \|x\| \langle dx_2, dx_1 \rangle$$

Первую норму дифференцируем аналогично через переход к скалярному квадрату:

$$= \frac{1}{\|x\|} \langle x, dx_2 \rangle \langle x, dx_1 \rangle + \|x\| \langle dx_2, dx_1 \rangle$$

Преобразуем в каноническую форму, для этого рассмотрим подробнее первое слагаемое:

$$\begin{aligned} \langle x, dx_2 \rangle \langle x, dx_1 \rangle &= \langle x, dx_1 \rangle \langle x, dx_2 \rangle \\ &= dx_1^\top x x^\top dx_2 = \langle x x^\top dx_2, dx_1 \rangle \end{aligned}$$

Осталось собрать общий канонический вид

$$d^2 f = \left\langle \left[\frac{1}{\|x\|} x x^\top + \|x\| I \right] dx_2, dx_1 \right\rangle$$

И получить итоговый ответ на задачу:

$$\nabla f = \|x\| x$$

$$\nabla^2 f = \frac{1}{\|x\|} x x^\top + \|x\| I$$

5 Комплексное дифференцирование

Комплексные параметры естественно возникают в обработке сигналов, оптике, реконструкции изображений и задачах с унитарными преобразованиями. При этом ошибка модели обычно вещественна:

$$z \in \mathbb{C}^n, \quad \mathcal{L}(z) \in \mathbb{R}, \quad \min_{z \in \mathbb{C}^n} \mathcal{L}(z).$$

Пусть $\Omega \subseteq \mathbb{C}$ открыто. Функция $f : \Omega \rightarrow \mathbb{C}$ комплексно дифференцируема в точке z_0 , если существует предел

$$f'(z_0) = \lim_{\substack{h \rightarrow 0 \\ h \in \mathbb{C} \setminus \{0\}}} \frac{f(z_0 + h) - f(z_0)}{h}. \quad (5.1)$$

Предел должен быть одинаковым по всем направлениям. Голоморфность означает комплексную дифференцируемость на открытом множестве.

Запишем $f = u + iv$, $z = x + iy$. Приращения $h = t$ и $h = it$, $t \in \mathbb{R}$, дают соответственно

$$f' = \frac{\partial u}{\partial x} + i \frac{\partial v}{\partial x}, \quad f' = \frac{\partial v}{\partial y} - i \frac{\partial u}{\partial y}.$$

Сравнение вещественной и мнимой частей приводит к условиям Коши–Римана:

$$\frac{\partial u}{\partial x} = \frac{\partial v}{\partial y}, \quad \frac{\partial u}{\partial y} = -\frac{\partial v}{\partial x}. \quad (5.2)$$

При условии вещественной дифференцируемости они также достаточны. Одного существования частных производных и равенств (5.2) без вещественной дифференцируемости недостаточно.

5.1 Дифференцирование вещественного оператора

Теорема 1. Пусть $\Omega \subseteq \mathbb{C}^n$ открыто и связно, а $\mathcal{L} : \Omega \rightarrow \mathbb{C}$ голоморфна и принимает только вещественные значения. Тогда $\mathcal{L}$ постоянна на Ω .

Доказательство. Запишем $\mathcal{L} = u + iv$. Так как $v \equiv 0$, условия Коши–Римана по каждой переменной $z_j = x_j + iy_j$ дают

$$\frac{\partial u}{\partial x_j} = \frac{\partial v}{\partial y_j} = 0, \quad \frac{\partial u}{\partial y_j} = -\frac{\partial v}{\partial x_j} = 0.$$

Все вещественные частные производные равны нулю. Поэтому u локально постоянна, а связность области обеспечивает её постоянство на всей области. $\square$

Получается, все наши лоссы не голоморфны. Мы не сможем использовать обычные комплексные производные. Выход — отождествление $z = x + iy \leftrightarrow (x, y)$. Это переводит задачу в пространство $\mathbb{R}^{2n}$.

Пример 2.

$$f(z) = |z|^2 = x^2 + y^2$$

Очевидно, функция не дифференцируема по z (кроме $z = 0$), но по (x, y) дифференцируется везде.

Вещественное евклидово скалярное произведение записывается как

$$\langle a, b \rangle_{\mathbb{R}} = \operatorname{Re}(a^H b), \quad \|a\|^2 = a^H a. \quad (5.3)$$

Обычный градиентный шаг имеет вид

$$x_t = x_{t-1} - \eta \frac{\partial \mathcal{L}}{\partial x}, \quad y_t = y_{t-1} - \eta \frac{\partial \mathcal{L}}{\partial y}, \quad \eta > 0. \quad (5.4)$$

Объединяя два равенства, получаем

$$z_t = z_{t-1} - \eta \left(\frac{\partial \mathcal{L}}{\partial x} + i \frac{\partial \mathcal{L}}{\partial y} \right).$$

5.2 Исчисление Виртингера

Можно ли как-то корректно дифференцировать, но при этом остаться в комплексных числах? На самом деле, мы можем линейно перейти от вещественных компонент (x, y) к комплексным $(z, \bar{z})$, но относиться к ним как к формальным переменным.

$$x = \frac{z + \bar{z}}{2}, \quad y = \frac{z - \bar{z}}{2i}$$

$$\begin{pmatrix} x \\ y \end{pmatrix} = \frac{1}{2} \begin{pmatrix} I & I \\ -iI & iI \end{pmatrix} \begin{pmatrix} z \\ \bar{z} \end{pmatrix}$$

Получаем определения:

$$\frac{\partial f}{\partial z} = \frac{1}{2} \left(\frac{\partial f}{\partial x} - i \frac{\partial f}{\partial y} \right), \quad \frac{\partial f}{\partial \bar{z}} = \frac{1}{2} \left(\frac{\partial f}{\partial x} + i \frac{\partial f}{\partial y} \right). \quad (5.5)$$

Это линейные комбинации вещественных производных, а не новое требование к дифференцируемости. Это так называемые *операторы Виртингера*.

Замечание 3. На настоящем пространстве переменных $\bar{z}$ является сопряжением z : они не могут изменяться независимо. Правило «считать z и $\bar{z}$ независимыми» — корректный формальный способ применять операторы (5.5). Оно не утверждает существование двух независимых комплексных степеней свободы и не требует голоморфного продолжения функции.

Пример 3.

$$\begin{aligned} f(z) &= |z|^2 = z\bar{z} = x^2 + y^2 \\ \frac{\partial f}{\partial z} &= \bar{z}, & \frac{\partial f}{\partial \bar{z}} &= z \\ \frac{\partial f}{\partial x} &= 2x, & \frac{\partial f}{\partial y} &= 2y \end{aligned}$$

Рассмотрим свойства для вещественно дифференцируемой комплекснозначной функции. Пользуясь определением, получаем такие равенства для сопряжения производных:

$$\overline{\frac{\partial f}{\partial z}} = \frac{1}{2} \left(\frac{\partial \bar{f}}{\partial x} + i \frac{\partial \bar{f}}{\partial y} \right) = \frac{\partial \bar{f}}{\partial \bar{z}} \quad (5.6)$$

$$\overline{\frac{\partial f}{\partial \bar{z}}} = \frac{1}{2} \left(\frac{\partial \bar{f}}{\partial x} - i \frac{\partial \bar{f}}{\partial y} \right) = \frac{\partial \bar{f}}{\partial z}. \quad (5.7)$$

Если функция f принимает вещественные значения, то получаем:

$$\overline{\frac{\partial f}{\partial z}} = \frac{\partial f}{\partial \bar{z}}, \quad \overline{\frac{\partial f}{\partial \bar{z}}} = \frac{\partial f}{\partial z} \quad (5.8)$$

Кроме того,

$$\frac{\partial f}{\partial \bar{z}} = \frac{1}{2} [(u_x - v_y) + i(v_x + u_y)].$$

Поэтому $\partial f / \partial \bar{z} = 0$ в точке равносильно условиям Коши–Римана в этой точке. При выполнении этого равенства во всей открытой области f голоморфна, причём $f' = \partial f / \partial z$.

Пример 4. Снова рассмотрим квадрат нормы

$$\begin{aligned} f(z) &= |z|^2 = z\bar{z} = x^2 + y^2 \\ \frac{\partial f}{\partial z} &= \bar{z}, & \frac{\partial f}{\partial \bar{z}} &= z \\ \frac{\partial f}{\partial x} &= 2x, & \frac{\partial f}{\partial y} &= 2y \end{aligned}$$

Действительно, свойства выполняются, и функция не дифференцируется нигде, кроме $z = 0$:

$$\begin{aligned} \overline{\frac{\partial f}{\partial z}} &= \bar{z} = z = \frac{\partial f}{\partial \bar{z}} \\ \frac{\partial f}{\partial \bar{z}} &= 0 \Leftrightarrow z = 0 \end{aligned}$$

5.3 Комплексные дифференциалы и chain-rule

Пусть $w = f(z)$, где $f : \mathbb{C}^m \rightarrow \mathbb{C}^n$ вещественно дифференцируема. Введём матрицы размера $n \times m$:

$$(J_z)_{kj} = \frac{\partial f_k}{\partial z_j}, \quad (J_{\bar{z}})_{kj} = \frac{\partial f_k}{\partial \bar{z}_j}.$$

Полный дифференциал и его сопряжение равны

$$dw = J_z dz + J_{\bar{z}} d\bar{z}, \quad (5.9)$$

$$d\bar{w} = \overline{J_z} dz + \overline{J_{\bar{z}}} d\bar{z}. \quad (5.10)$$

В блочной форме

$$\begin{pmatrix} dw \\ d\bar{w} \end{pmatrix} = \mathcal{J}_f \begin{pmatrix} dz \\ d\bar{z} \end{pmatrix}, \quad \mathcal{J}_f = \begin{pmatrix} J_z & J_{\bar{z}} \\ \overline{J_z} & \overline{J_{\bar{z}}} \end{pmatrix}. \quad (5.11)$$

Поэтому для композиции $q \circ f$ $\mathcal{J}_{q \circ f}(z) = \mathcal{J}_q(f(z))\mathcal{J}_f(z)$. Это обычное chain-rule в другой записи.

5.4 Оптимизация

Вспомним, как у нас выглядит шаг градиентного спуска с переходом в $\mathbb{R}^{2n}$:

$$z_t = z_{t-1} - \eta \left(\frac{\partial \mathcal{L}}{\partial x} + i \frac{\partial \mathcal{L}}{\partial y} \right).$$

Применим определение оператора Виртингера:

$$z_t = z_{t-1} - 2\eta \frac{\partial \mathcal{L}}{\partial \bar{z}}.$$

Получаем шаг оптимизации с использованием сопряжённой производной Виртингера. Бонус: можно посмотреть, как «conjugate Wirtinger derivative» используется в torch¹.

6 Задача. Phase retrieval: восстановление голоса по спектрограмме

6.1 Постановка

Сигнал $x \in \mathbb{R}^N$ режем на перекрывающиеся кадры длины L с шагом H , каждый умножаем на окно w и преобразуем по Фурье:

$$Z_{t,f} = \sum_{j=0}^{L-1} w_j x_{tH+j} e^{-2\pi i f j / L}, \quad \text{коротко} \quad Z = Gx, \quad G \in \mathbb{C}^{TL \times N}.$$

Спектрограмма Z комплексна, но почти вся обработка звука использует только модуль $M = |Z|$: акустическая модель TTS предсказывает мел-спектрограмму, шумоподавление применяет маску к амплитуде, эквалаизация работает с амплитудой. Фаза $\arg Z$ при этом просто выбрасывается.

¹<https://docs.pytorch.org/docs/2.14/notes/autograd.html#autograd-for-complex-numbers>

Восстанавливать её приходится потому, что кадры перекрываются и при overlap-add складываются. Если фазы соседних кадров не согласованы, их вклады частично гасят друг друга, атаки и транзиенты размазываются — на слух это тот самый «железный», металлически звенящий голос.

Задача. По амплитудной спектрограмме M найти сигнал x такой, что $|Gx| = M$.

6.2 Функционал

Наблюдаем M , модель предсказывает $|Gx|$ — пишем наименьшие квадраты:

$$\mathcal{L}(Z) = \frac{1}{2} \sum_{t,f} \left(|Z_{t,f}| - M_{t,f} \right)^2, \quad Z = Gx.$$

Сразу заметим главное. Функционал зависит от Z **только через модуль** — иначе он использовал бы фазу, которой у нас нет. Значит $\mathcal{L}$ вещественнозначен, а непостоянный вещественнозначный функционал нигде не голоморфен. Комплексной производной $\mathcal{L}'$ не существует, и дифференцировать придётся по Виртингеру.

6.3 Дифференцируем

Шаг 1. Производная модуля

Записываем модуль через сопряжение и дифференцируем по $\bar{Z}$, считая Z константой:

$$|Z| = \sqrt{Z\bar{Z}} \quad \Longrightarrow \quad \frac{\partial |Z|}{\partial \bar{Z}} = \frac{Z}{2|Z|} = \frac{1}{2} e^{i \arg Z}$$

Половина единичного вектора текущей фазы. (В нуле особенность — это излом модуля.)

Шаг 2. Градиент по коэффициенту спектрограммы

Внешняя производная берётся как обычно, невязка вещественна:

$$\frac{\partial \mathcal{L}}{\partial \bar{Z}_{t,f}} = (|Z_{t,f}| - M_{t,f}) \cdot \frac{Z_{t,f}}{2|Z_{t,f}|} = \frac{1}{2} (Z_{t,f} - M_{t,f} e^{i \arg Z_{t,f}}).$$

В скобках — разность между текущим коэффициентом и «целевым»: тем, у которого фаза оставлена своя, а модуль заменён на требуемый.

Шаг 3. Цепочка до сигнала

Здесь конфигурация $\mathbb{R}^N \rightarrow \mathbb{C}^{TL} \rightarrow \mathbb{R}$: вещественный вход, комплексная середина, вещественный выход. Из $Z = Gx$ следует $dZ = G dx$, причём dx вещественно, поэтому

$$\begin{aligned} d\mathcal{L} &= 2 \operatorname{Re} \left((\nabla_{\bar{Z}} \mathcal{L})^H dZ \right) \\ &= 2 \operatorname{Re} \left((\nabla_{\bar{Z}} \mathcal{L})^H G dx \right) \\ &= 2 \left[\operatorname{Re} \left(G^H \nabla_{\bar{Z}} \mathcal{L} \right) \right]^T dx, \end{aligned}$$

откуда

$$\nabla_x \mathcal{L} = 2 \operatorname{Re} \left(G^H \nabla_{\bar{Z}} \mathcal{L} \right)$$

Вещественная часть в конце появилась ровно потому, что вариация входа заперта на вещественной оси. Оператор G^H — это сопряжённое ДПФ, сопряжённое окно и overlap-add, то есть обратный STFT.

Ответ

Подставляем шаг 2 в шаг 3:

$$\nabla_x \mathcal{L} = \operatorname{Re} \left(G^H [Z - M \odot e^{i \arg Z}] \right), \quad Z = Gx.$$

Читается буквально: посчитать невязку в спектральной области и сделать обратный STFT.

6.4 Бонус: что это за метод

Пусть окно и шаг образуют тугой фрейм, $G^H G = cI$ (например $w = \sqrt{\text{Hann}}$ с перекрытием 50%); тогда обратный STFT — это $G^+ = G^H/c$. Поскольку $\operatorname{Re}(G^H Gx) = cx$, получаем

$$\nabla_x \mathcal{L} = cx - \operatorname{Re} \left(G^H [M \odot e^{i \arg Z}] \right),$$

и градиентный шаг с $\eta = 1/c$ схлопывается в

$$x \leftarrow G^+ \left(M \odot e^{i \arg Gx} \right)$$

— взять текущие фазы, подставить целевые амплитуды, сделать обратный STFT. Это в точности итерация **алгоритма Гриффина–Лима (1984)**. Классический метод чередующихся проекций и градиентный спуск по нашему функционалу — один и тот же алгоритм, записанный двумя способами.