

Семинар: вероятностная постановка задачи в машинном обучении. Логистическая регрессия

Табаченков Андрей Михайлович

Богданов Александр Дмитриевич

Федоров Артем Максимович

Афанасьев Глеб Ильич

Октябрь, 2026

1 Введение

Данный семинар предназначен познакомить слушателей с вероятностной парадигмой машинного обучения. Для начала введем условия решаемой задачи в общем виде:

1. Дано некоторое множество Ω объектов ω .
2. Каждый объект ω изучаемого множества может быть представлен в виде набора из s численных признаков $g_i(\omega)$, где $g_i : \Omega \rightarrow \mathbb{R}, i = \overline{1, s}$.
3. Каждый объект ω также обладает некоторыми скрытыми свойствами k , не представленными в признаковом описании $\vec{g}(\omega) = (g_1(\omega), \dots, g_s(\omega))$.
4. В задаче также определена выборка $(X_N, K_N) = \{(x_1, k_1), \dots, (x_N, k_N)\} \subset \vec{g}(\Omega) \times K$, по которой требуется минимизировать риск $\mathcal{R}(q) \rightarrow \min_{q \in M}, M$ - класс стратегий.

Таким образом, целью задачи является восстановить закон $q : \vec{g} \rightarrow K$, по которому из имеющегося признакового описания $x = g(\omega)$ каждого объекта мы определяем скрытую информацию о нем.

Пример 1

Задача: предсказать потребность в ремонте станка

- Ω – все возможные состояния станка
- g_i – данные снятые с датчика
- $K = \{0, 1\}$ – сломается ли станок в ближайшую неделю

Пример 2

Задача: определить ущерб после стихийного бедствия

- Ω – стихийное бедствие
- g_i – его параметры (место, время, оценка силы ...)
- $K = [0, +\infty]$ – стоимость ущерба инфраструктуре и частной собственности

Зачем нам вообще предсказывать именно вероятности?

Вы уже знакомы с линейными классификаторами, которые предсказывают только метку класса. Но почему бы нам не ограничиться только ими? Рассмотрим несколько примеров, когда предсказание вероятностей даёт выигрыш в реальных задачах.

Пример 1. Кредитный скоринг

Рассмотрим задачу кредитного скоринга. Линейный классификатор

$$a(x) = \text{sign}(\langle x, w \rangle)$$

выдаёт бинарный ответ: «клиент вернёт кредит» или «клиент не вернёт кредит». Какие расчёты мы можем сделать, исходя из ответов этого классификатора? Как предпринимателю, нам нужно рассчитывать прибыль

и наши потери, если клиент не вернёт кредит. Исходя из бинарной метки мы не можем сделать какие-либо разумные выводы.

Допустим, если клиент возвращает кредит, банк получает чистую прибыль $G = 1\,000$ рублей. Если клиент не возвращает кредит, банк несёт чистый убыток $L = 9\,000$ рублей. Отказ от выдачи кредита даёт нулевую прибыль.

Пусть модель оценивает вероятность возврата:

$$p(x) = \mathbb{P}(\text{клиент вернёт кредит} \mid x).$$

Тогда ожидаемая прибыль от выдачи кредита равна

$$\mathbb{E}[\Pi \mid x] = p(x)G - (1 - p(x))L.$$

Например, для клиента с $p(x) = 0.95$ получаем

$$\mathbb{E}[\Pi \mid x] = 0.95 \cdot 1\,000 - 0.05 \cdot 9\,000 = 500 \text{ рублей.}$$

Для клиента с $p(x) = 0.85$:

$$\mathbb{E}[\Pi \mid x] = 0.85 \cdot 1\,000 - 0.15 \cdot 9\,000 = -500 \text{ рублей.}$$

При стандартном пороге 0.5 оба клиента получили бы одинаковую метку «вернёт кредит», хотя ожидаемый финансовый результат для них различается.

Как выбрать порог выдачи кредита? В этой упрощённой модели кредит выгодно выдавать, если его ожидаемая прибыль положительна:

$$p(x)G - (1 - p(x))L > 0 \iff p(x) > \frac{L}{G + L}.$$

Таким образом, порог определяется финансовыми последствиями решения. В нашем примере он равен

$$t = \frac{9\,000}{1\,000 + 9\,000} = 0.9.$$

Чем больше возможный убыток относительно прибыли, тем выше порог. Поэтому порог 0.5 не является универсальным: вероятностная модель позволяет выбирать его под конкретную задачу и стоимость ошибок.

Пример 2. Выбор рекламного баннера

Допустим, мы показываем пользователю рекламные баннеры и получаем от рекламодателей плату за каждый клик. Для одного рекламного места нужно выбрать один из двух баннеров.

Обозначим через $p_i(x)$ вероятность того, что пользователь с признаками x кликнет по баннеру i , а через r_i — плату за этот клик. Если пользователь не кликает, мы ничего не получаем.

Доход от одного показа является случайной величиной:

$$R_i = \begin{cases} r_i, & \text{если пользователь кликнул,} \\ 0, & \text{если пользователь не кликнул.} \end{cases}$$

Следовательно, ожидаемый доход равен

$$\mathbb{E}[R_i \mid x] = p_i(x)r_i.$$

Баннер	Вероятность клика	Плата за клик	Ожидаемый доход
A	0.02	50	1.00
B	0.05	15	0.75

Таблица 1: Ожидаемый результат одного показа баннера

Пользователь с большей вероятностью кликнет по баннеру B, но баннер A приносит большую ожидаемую прибыль благодаря более высокой плате за клик. Поэтому для максимизации ожидаемой прибыли мы выбираем

$$i^*(x) = \arg \max_i (p_i(x)r_i).$$

В обоих примерах важно, чтобы предсказанные вероятности соответствовали реальной частоте событий: от этого зависит точность расчёта ожидаемой прибыли.




Рис. 1: Прообразы всех возможных наблюдений эксперимента. ($\cdot$ – объект из X_N , M - man, W - woman, $\mathcal{U} - g^{-1}(x)$)

2 Вероятностная парадигма машинного обучения

Рассмотрим задачу определения пола человека по его фотографии. Для этого будет подразумеваться, что была определена случайная выборка людей (например с улицы) и фотосъемка проводилась в разных условиях (погода, разные камеры, разная одежда на людях) - каждый рецензент проходил ровно один раз. Тогда $\Omega = \Omega_1 \times \Omega_2$ - все возможные обстоятельства, повлиявшие на пол человека и его внешний вид, а также все условия, влияющие на фотографию человека. $K = \{M, W\}$ – есть пол человека.

Пусть у нас есть наблюдение $x \in \vec{g}(\Omega)$. Рассмотрим прообраз $\mathcal{U} = \vec{g}^{-1}(x) \subset \Omega$. Обозначим за Ω_M и Ω_W - подмножества Ω с фотографиями мужчин и фотографиями женщин. Для простоты можно предположить, что $\Omega_M \cap \Omega_W = \emptyset$, $\Omega_M \cup \Omega_W = \Omega$.

Заметим, что вообще говоря, пересечения $\mathcal{U} \cap \Omega_M$ и $\mathcal{U} \cap \Omega_W$ оба могут быть непусты ¹, так как отображение $\vec{g}$ не обязательно биективно. Значит, мы, вообще говоря, не можем построить в общем случае полностью правильный классификатор пола для данной задачи, мы лишь можем только рассматривать вероятности $\mathbb{P}(M|\mathcal{U}) = \frac{|\mathcal{U} \cap \Omega_M|}{|\mathcal{U}|}$, $\mathbb{P}(W|\mathcal{U}) = \frac{|\mathcal{U} \cap \Omega_W|}{|\mathcal{U}|}$ и предполагать, что $k = M \Leftrightarrow \mathbb{P}(M|\mathcal{U}) \gg \mathbb{P}(W|\mathcal{U})$. Таким образом, в рамках вероятностной парадигмы мы стремимся устранить этот недостаток, оценивая соответствующие условные распределения.

Для соответствия задачи машинного обучения вероятностной парадигме достаточно потребовать:

1. Измеримость функций g_i .
2. Наличие в выборке (X_N, K_N) всех объектов из генеральной совокупности исследуемого множества.
3. Одновременное существование вероятностей

$$\mathbb{P}(x, k), \mathbb{P}(x), \mathbb{P}(k), \mathbb{P}(x|k), \mathbb{P}(k|x)$$

4. Существование функции потерь $\mathcal{L} : K \times X \times K \rightarrow \mathbb{R}$, где $\mathcal{L}$ - определена и интегрируема по Лебегу.
5. Представимость минимизируемого риска в следующем виде: $\mathcal{R}(q) = \mathbb{E}_{X,K}[\mathcal{L}(q(x), x, k)] \rightarrow \min_{q \in M}$.

$$\begin{aligned} \mathbb{E}_{X,K} [\mathcal{L}(q(x), k, x)] &= \int_X \int_K p(x, k) \mathcal{L}(q(x), x, k) dx dk = \\ &= \int_X p(x) dx \int_K p(k|x) \mathcal{L}(q(x), x, k) dk \end{aligned}$$

Данная задача называется генеративной задачей машинного обучения, лежащей в основе Байесовского метода распознавания и используемая всюду, от *Sklearn* до глубокого обучения. Основная причина, почему вероятностная модель (говоря простыми словами, модель оценивающая меры множеств) настолько удобна заключается в том, что мы способны автоматически обрабатывать неточности данных, задавать аналитически плоскость лосса и прочие приятные фишки аппарата теории вероятностей. Огромным преимуществом

генеративных моделей также является то, что мы обучаем совместное распределение целевой метки и наблюдений, следовательно мы можем не только решать задачу нахождения k , но и генерировать объекты из X .

3 Проблемы генеративных моделей

Одной из основных проблем генеративных моделей является обязательное условие существования априорных распределений, хотя моделирование таких априорных распределений не всегда возможно и зачастую трудо-затратно. Кроме того, если говорить отдельно о $\mathbb{P}(x)$, то зачастую от нас даже не требуется понимать вероятностную природу множества X . Далее приведем примеры, иллюстрирующие проблемы генеративных моделей, при использовании их на практике:

1. **Пример Не Байесовской задачи:** Пусть вы работаете на военной базе главным аналитиком. Вам поручено разработать систему "Свой-чужой основанную на визуальных и ЭРЛС данных о самолетах противника и союзников. Имея опыт работы с данными вы быстро понимаете, что речь идет о вероятностной задаче бинарной классификации. Однако можно ли применить в данном случае генеративный подход?

Оказывается, что нет! Первым же делом возникает вопрос: что такое априорная вероятность события "Вражеский самолет"? Как мы можем оценить вероятность события, что в действительности не может происходить в мирное время, а если и произошло, то это явно признак "неординарной" ситуации. Более формально ситуацию может разъяснить теория вероятностей: мы считаем вероятность события равной $p \iff$ при бесконечном проведении независимых опытов, событие будет воспроизводиться с частотой p . Соответственно, в данной задаче такой вероятности быть просто не может в мирное время, в котором система действовать и обязана.

2. **Пример неслучайной выборки:** Однако не всегда проблема кроется исключительно в задаче. Пусть задача состоит в оценке состояния оборудования завода по численным признакам с датчиков. Из огромного числа логов заказчик выбирает 100 наиболее характерных примеров состояний и таргет значений. Тогда такая ситуация так же становится не разрешимой с точки зрения генеративных моделей, так как неслучайная выборка не позволяет нам оценить априорные распределения событий.

Поэтому, чтобы остаться в рамках вероятностной парадигмы машинного обучения, принято переходить к рассмотрению дискриминативной задачи $\mathbb{E}_K[\mathcal{L}(q(x), x, k)|X] \rightarrow \min_{q \in M}$, то есть мы стремимся по наблюдению x предсказать только k , забывая о совместных распределениях и вероятностной природе X , что также требует меньше данных и позволяет бороться с проблемами, описанными выше.

4 Задача бинарной классификации

Пусть теперь множество таргетов $K = \{-1, 1\}$, то есть мы рассматриваем задачу бинарной классификации. Возникает вопрос, какую функцию потерь следует использовать. Наиболее простой способ - использовать ассигасу:

$$\mathcal{R}(q) = \frac{1}{N} \sum_{i=1}^N [q(x_i) \neq k_i]$$

Несмотря на простоту и интуитивную понятность, есть ряд недостатков.

1. Такой лосс не является дифференцируемым в каноническом смысле. Более того, так как функция кусочно-постоянная, даже если мы попадем в точку, где она дифференцируема, то мы не сможем сделать шаг в сторону уменьшения лосса, так как градиент в такой точке будет равен 0 $\Rightarrow$ оптимизация не более чем методами 0-порядка.
2. Поверхность данного лосса очень сложная с "постоянными" локальными минимумами (см. рис. 3).

Введем в рассмотрение отступы $m_i = q(x_i)k_i$ (в данном случае под $q(\cdot) : X \rightarrow \mathbb{R}$ также понимается дискриминативная функция). Тогда мы можем приблизить сверху ранее описанную функцию потерь другой функций потерь (рис. 2), которая уже не обладает вышеописанными проблемами:

$$\mathcal{R}(q) \leq \hat{\mathcal{R}}(q) = \frac{1}{N} \sum_{i=1}^N \hat{\mathcal{L}}(m_i)$$




Рис. 2: Примеры лосс функций




Рис. 3: Демонстрация assigury loss функции в пространстве параметров

Однако, далеко не факт, что мы можем использовать данную функцию потерь в рамках вероятностной парадигмы.

5 Критерий вероятностной природы лосса

Чтобы понять, какими свойствами должна обладать функция потерь в вероятностной парадигме в задаче бинарной классификации, рассмотрим для начала следующий пример.

Пусть поставлена задача рекомендации пользователю рекламы. Аналитики компании уже проанализировали систему Ω и построена функция $g : \Omega \rightarrow \{1, 2, 3, \dots, l\}$, что показывает некоторый категориальный признак для пары "реклама $\times$ пользователь". По полученной выборке (X_N, K_N) обучить стратегию определять вероятность того, что пользователь перейдет по рекламе. Тогда очевидно:

$$\sum_{i=1}^N \frac{\mathbf{1}\{Click|x_i = j\}}{\#(x = j)} = \frac{\text{кликков при } j}{\text{всего наблюдений } j} \xrightarrow{n \rightarrow \infty} p(Click | j)$$

Будем считать, что обучающая выборка нашей модели настолько велика, насколько мы захотим ($N \rightarrow \infty$). Тогда для любого наблюдаемого значения $j \in \{1, 2, 3, \dots, l\}$ мы сможем получить вероятность $p(\text{пользователь кликнул} | j) = 1 - p(\text{пользователь не кликнул} | j)$ и соответственно будем хотеть от нашей вероятностной модели выдавать ровно такие же значения на наблюдения x :

$$q(x = j) = p(Click | j)$$

Вернемся теперь к общему случаю. Как итог, нам хотелось бы, чтобы оптимальная модель $q \in M$ приближала вероятность положительного класса для каждого из наблюдений (при достаточно большом N).

$$\min_{q \in M} \hat{\mathcal{R}}(q) = \min_{q \in M} \mathbb{E}[\hat{\mathcal{L}}(q(x), x, k) | x] = \min_{q \in M} \mathbb{E}[m_i | x]$$

$$\arg \min_{q \in M} \hat{\mathcal{R}}(q) \xrightarrow{N \rightarrow +\infty} \mathbb{P}(k = 1 | \cdot)$$

5.1 Интерпретация данного результата на более сложных моделях

Пусть для пространства признаков выполнено условие "континуальности" (непрерывности из лекций Воронцова). Тогда мы фактически говорим, что отображение g ставит близкие объекты относительно изначального Ω близко друг другу и в пространстве признаков. Тогда мы можем говорить, что при его разбиении на малые области (**квантизация** X), разумная модель для каждого объекта будет выдавать вероятности, равные отношению классов в данной области.

$$\rho(x, c) \leq \delta \Rightarrow \mathcal{R} = \sum \tilde{\mathcal{L}}(x) \approx \sum [\tilde{\mathcal{L}}(c) + \bar{\mathcal{O}}(x - c)] \approx \sum \tilde{\mathcal{L}}(c)$$

Функция потерь на близких объектах будет практически равна одному и тому же, а значит и при обучении на таких объектах должны в «идеале» выдаваться почти одинаковые вероятности. Но тогда

$$\text{доля классов} = \mathbb{P}(k = 1 | \rho(x, c) \leq \delta) = \int_{\rho(x, c) \leq \delta} p(k = 1 | x) d\mathbb{P}(x | \rho(x, c) \leq \delta) \approx$$

$$\approx p(k = 1 | c) \int_{\rho(x, c) \leq \delta} d\mathbb{P}(x | \rho(x, c) \leq \delta) = p(k = 1 | c) \Rightarrow$$

$$\Rightarrow p(k = 1 | x) \approx p(k = 1 | c) = \text{доля классов} \square$$

5.2 Примеры проверки по критерию

Задача 1: Задача бинарной классификации: $\mathcal{L}(q, x, k) = (q(x) - [k = +1 | x])^2 - \text{MSE}$.

$$\arg \min_q \mathbb{E}(\mathcal{L}(q, x, k) | x) = \arg \min_q \left[(q(x) - 1)^2 \underbrace{p(k = +1 | x)}_p + q^2(x) \underbrace{p(k = -1 | x)}_{1-p} \right]$$

$$\frac{\partial}{\partial q(x)} \mathbb{E}(\mathcal{L}(q, x, k) | x) = 2(q(x) - 1)p + 2q(x)(1 - p) = 0 \Rightarrow q(x) = p(k = +1 | x)$$

Задача 2: Задача бинарной классификации: $\mathcal{L}(q, x, k) = |q(x) - [k = +1 | x]| - \text{MAE}$.

$$\begin{aligned} \arg \min_q \mathbb{E}(\mathcal{L}(q, x, k) | x) &= \arg \min_q \left[|q(x) - 1| \underbrace{p(k = +1 | x)}_p + |q(x)| \underbrace{p(k = -1 | x)}_{1-p} \right] \\ \arg \min_q [p(1 - q(x)) + q(x)(1 - p)] &= \arg \min_q [p + q(x) - 2pq(x)] \Rightarrow \\ &\Rightarrow q(x) \neq p(k = +1 | x) \end{aligned}$$

6 Задание функции потерь из вероятностного распределения

Теперь будем рассматривать только линейные классификаторы. Тогда в общем виде получаем, что $q(x|w) = f(\langle x, w \rangle)$, где функция f нормирует выход линейной функции на отрезок $[0, 1]$.

Чего мы хотим добиться с вероятностной точки зрения? Мы хотим решить дискриминативную задачу: найти условное распределение на метку класса и на параметры модели, при условии данных x . Формально:

$$p(k, w | x) = p(k | w, x) p(w | x).$$

Предполагаем, что априорное распределение на параметры не зависит от данных, тогда:

$$p(k, w | x) = \underbrace{p(k | w, x)}_{\text{likelihood}} \cdot \underbrace{p(w)}_{\text{prior}}.$$

Для получения оценки на параметры модели, можно максимизировать распределение по параметрам:

$$w_{MAP} = \arg \max_w p(k, w | x) = \arg \max_w p(k | w, x) p(w).$$

Данный метод называется методом Maximum a Posteriori Estimation (MAP). Распишем по выборке:

$$p(k, w | x) = \prod_{i=1}^N p(k_i | w, x_i) p(w).$$

Оптимизация произведения — это сложная задача, с вычислительной точки зрения. Более того, каждый член произведения — число из отрезка $[0, 1]$. При больших N , вычисление произведения и производных будет приводить к численным ошибкам. Поэтому принято оптимизировать логарифм правдоподобия:

$$\log p(k, w | x) = \sum_{i=1}^N \log p(k_i | w, x_i) + \log p(w).$$

Какой смысл имеет слагаемое $\log p(w)$? Априорное распределение $p(w)$ позволяет дополнительно задать, какие значения параметров мы считаем более правдоподобными до наблюдения меток.

Рассмотрим простой пример. В нашей линейной модели параметрами являются веса w . Предположим, что они имеют нормальное априорное распределение с нулевым средним:

$$p(w) \propto \exp \left\{ -\frac{\|w\|_2^2}{2\tau^2} \right\}.$$

Такое предположение означает, что мы предпочитаем веса, близкие к нулю: большие по модулю значения возможны, но должны быть обоснованы наблюдаемой выборкой.

После перехода к минимизации отрицательного логарифма получаем

$$w_{MAP} = \arg \min_w \left[-\sum_{i=1}^N \log p(k_i | w, x_i) + \frac{1}{2\tau^2} \|w\|_2^2 \right].$$

Это и есть знакомая нам L_2 -регуляризация.

Далее используем метод максимального правдоподобия (то есть максимизировать только **likelihood**): рассматриваем параметры как фиксированные неизвестные величины и выбираем их по соответствию наблюдаемым данным. Априорное распределение параметров $p(w)$ не задаём. Его введение привело бы к

МАР-оценке и позволило бы учитывать дополнительные предпочтения относительно параметров, но для вывода логистической регрессии это не нужно.

Выше мы поставили задачу, как нахождения нашей оптимальной модели $q(x|w) = f(\langle x, w \rangle)$. То есть модель имеет две основные компоненты: линейный предиктор $\langle x, w \rangle$ и нелинейная функция f , которая преобразует его вероятность. Существует аппарат, который обобщает данную модель и позволяет строить модели для различных типов ответа. Этот аппарат называется **обобщённая линейная модель** (GLM, Generalized Linear Model).

6.1 Экспоненциальное семейство распределений

Чтобы построить GLM, нам нужно сначала определить, какие распределения могут быть использованы в качестве распределения целевой метки.

Распределение принадлежит экспоненциальному семейству, если его плотность или функцию вероятности можно записать в виде

$$p(k | \theta) = b(k) \exp\{\theta T(k) - c(\theta)\}.$$

Здесь θ — натуральный, или канонический, параметр, $T(k)$ — достаточная статистика, а $b(k)$ — множитель, не зависящий от θ . Функция $c(\theta)$ обеспечивает нормировку распределения:

$$c(\theta) = \log \int b(k) \exp\{\theta T(k)\} dk.$$

Таким образом, $c(\theta)$ не является произвольной функцией: её вид определяется тем, чтобы суммарная вероятность была равна единице.

Для построения GLM будем рассматривать частный случай с $T(k) = k$, допускающий параметр дисперсии $\varphi > 0$:

$$p(k | \theta, \varphi) = \exp \left\{ \frac{k\theta - c(\theta)}{\varphi} + h(k, \varphi) \right\}.$$

Обратите внимание: слагаемое $h(k, \varphi)$ зависит от наблюдения k и параметра φ , но не от θ .

Оказывается, производные $c(\theta)$ задают основные характеристики этого распределения:

$$\mathbb{E}k = c'(\theta), \quad \mathbb{D}k = \varphi c''(\theta).$$

Эти равенства выполняются при стандартных условиях регулярности, позволяющих дифференцировать нормирующий интеграл или сумму.

Первое равенство можно получить непосредственно из условия нормировки:

$$0 = \frac{\partial}{\partial \theta} \int p(k | \theta, \varphi) dk = \int \frac{k - c'(\theta)}{\varphi} p(k | \theta, \varphi) dk.$$

Следовательно, $\mathbb{E}k = c'(\theta)$. Повторное дифференцирование даёт $\mathbb{D}k = \varphi c''(\theta)$.

Так как дисперсия неотрицательна, $c''(\theta) \geq 0$, то есть функция c выпукла. Для невырожденного распределения $c''(\theta) > 0$, поэтому $c'(\theta)$ строго возрастает и позволяет восстановить θ по математическому ожиданию.

6.2 Обобщённая линейная модель

Обобщённая линейная модель (GLM, Generalized Linear Model) состоит из трёх частей:

1. Условное распределение целевой переменной принадлежит рассмотренному экспоненциальному семейству:

$$p(k_i | x_i, w, \varphi) = \exp \left\{ \frac{k_i \theta_i - c(\theta_i)}{\varphi} + h(k_i, \varphi) \right\}.$$

2. По признакам объекта вычисляется линейный предиктор

$$\eta_i = \langle x_i, w \rangle.$$

Свободный член при необходимости включаем в w , добавив к признакам постоянную координату 1.

3. Математическое ожидание целевой переменной $\mu_i = \mathbb{E}[k_i | x_i]$ связано с линейным предиктором **функцией связи**:

$$g(\mu_i) = \eta_i.$$

Функция связи позволяет согласовать область значений математического ожидания с линейным предиктором. Например, вероятность должна лежать в $(0, 1)$, тогда как $\langle x_i, w \rangle$ может принимать любое действительное значение.

Так как $\mu_i = c'(\theta_i)$, естественным выбором является **каноническая функция связи**:

$$g(\mu_i) = (c')^{-1}(\mu_i).$$

При таком выборе

$$\theta_i = \eta_i = \langle x_i, w \rangle, \quad \mu_i = c'(\langle x_i, w \rangle).$$

Таким образом, в GLM с канонической связью линейная модель предсказывает натуральный параметр распределения. Математическое ожидание мы получаем из него с помощью c' . Другие функции связи также возможны, но далее мы рассматриваем именно каноническую.

6.3 Вывод логистической регрессии

Для бинарной метки естественно использовать распределение Бернулли. Для вывода перейдём от $k_i \in \{-1, +1\}$ к $y_i = (k_i + 1)/2 \in \{0, 1\}$. Тогда

$$\mu_i = \mathbb{E}[y_i | x_i] = p(k_i = +1 | x_i),$$

а функция вероятности имеет вид

$$p(y_i | \mu_i) = \mu_i^{y_i} (1 - \mu_i)^{1-y_i}.$$

Приведём её к канонической форме:

$$\begin{aligned} p(y_i | \mu_i) &= \exp \{ y_i \log \mu_i + (1 - y_i) \log(1 - \mu_i) \} \\ &= \exp \left\{ y_i \log \frac{\mu_i}{1 - \mu_i} + \log(1 - \mu_i) \right\}. \end{aligned}$$

Следовательно,

$$\theta_i = \log \frac{\mu_i}{1 - \mu_i}, \quad \varphi = 1, \quad h(y_i, \varphi) = 0.$$

Нормирующая функция и её производная имеют вид

$$c(\theta) = \log(1 + e^\theta), \quad c'(\theta) = \frac{e^\theta}{1 + e^\theta} = \sigma(\theta).$$

Это согласуется с общим равенством $\mu_i = c'(\theta_i)$ для GLM.

Выразим μ_i через натуральный параметр:

$$e^{\theta_i} = \frac{\mu_i}{1 - \mu_i} \implies \mu_i = \frac{1}{1 + e^{-\theta_i}} = \sigma(\theta_i).$$

Так как **функция связи каноническая**, то

$$g(\mu_i) = \theta_i = \log \frac{\mu_i}{1 - \mu_i}.$$

При выборе канонической функции связи, натуральный параметр равен предиктору, тогда:

$$\theta_i = \langle x_i, w \rangle, \quad q(x_i | w) = p(k_i = 1 | x_i, w) = \sigma(\langle x_i, w \rangle).$$

Таким образом, сигмоида возникает как обратная каноническая функция связи для распределения Бернулли.

Осталось получить функцию потерь.

$$\begin{aligned} L(w) &= - \sum_{i=1}^N \log p(y_i | w) = - \sum_{i=1}^N \log (\sigma(\langle x_i, w \rangle)^{y_i} (1 - \sigma(\langle x_i, w \rangle))^{1-y_i}) = \\ &= \boxed{- \sum_{i=1}^N (y_i \log \sigma(\langle x_i, w \rangle) + (1 - y_i) \log (1 - \sigma(\langle x_i, w \rangle)))}. \end{aligned}$$

Это **бинарная кросс-энтропия** для меток $y_i \in \{0, 1\}$.

Потери для меток $k_i \in \{-1, +1\}$. Для положительной метки вероятность равна $\sigma(z_i)$, а для отрицательной $1 - \sigma(z_i) = \sigma(-z_i)$. Перепишем функцию потерь в терминах k_i :

$$\begin{aligned}
 L(w) &= - \sum_{i=1}^N \log p(k_i|w) = - \sum_{i=1}^N \log(\sigma(\langle x_i, w \rangle)^{[k=+1|x_i]} (1 - \sigma(\langle x_i, w \rangle))^{[k=-1|x_i]}) = \\
 &= - \sum_{i=1}^N ([k=+1|x_i] \log \sigma(\langle x_i, w \rangle) + [k=-1|x_i] \log(1 - \sigma(\langle x_i, w \rangle))) = \\
 &= - \sum_{i=1}^N \log \sigma(k_i \langle x_i, w \rangle) = \boxed{\sum_{i=1}^N \log(1 + e^{-k_i \langle x_i, w \rangle})}
 \end{aligned}$$

7 Оценка качества восстановления вероятностей модели

Построение вероятностной задачи не является панацеей, так как модель может быть недообучена или переобучена на задачу, выбранное распределение таргет переменных которой может отличаться от наших ожиданий, тем самым вся модель будет предсказывать совершенно неестественные распределения на объектах. Хотелось бы вывести (аналитически) более эмпирическую оценку качества вероятностной модели, нежели «суррогатный» эмпирический риск $\mathcal{R}$.

Диаграмма калибровки




Рис. 4: Диаграмма калибровки

Рассмотрим такую ситуацию: для задачи бинарной классификации определим набор моделей, каждая обучаемая на различные гипотезы об апостериорном распределении таргета и с различными гиперпараметрами. Тогда для каждой модели строим «диаграммы калибровки»:

1. Разбиваем ось $[0, 1]$ на бины измельчением $\{a_1, a_2, \dots, a_\ell\}$, $[a_i, a_{i+1}] = \mathbb{B}_i$
2. Для каждого объекта высчитываем оценку вероятности +1 класса $p_i \in \mathbb{B}_i$
3. Для каждого бина считаем отношение попавших в него действительно +1 классов к общему числу попавших.

Примеры калибровочных диаграмм




Рис. 5: Примеры калибровочных диаграмм

Такие диаграммы выполняют вполне осязаемую функцию: показать, насколько сильно предсказанная вероятность модели отличается от действительной выборочной.

По аналогии с примером про компактные выборки, нетрудно показать, что, так как распределения $+1$ классов у объектов в бине примерно одни и те же, то тогда (если модель оценивает распределения практически идеально) они все должны быть примерно равны посчитанному отношению. Именно на этом и основан принцип таких диаграмм.

На примере (рис. 5) отчетливо видны 5 ситуаций:

1. **Desired:** Идеальное поведение классификатора, к которому мы стремимся при обучении вероятностной модели
2. **Uncertain on bound:** модель, что отдает сильное предпочтение сильно отдаленным объектам. В таком случае крайне вероятно переобучение.
3. **To confident:** модель предсказывает каждый из классов слишком уверенно
4. **patologic +1 bias:** модель старательно отдает предпочтение -1 классу. Эта ситуация является поводом задуматься о смене либо модели данных, либо о классе моделей мл
5. **patologic -1 bias:** противоположная ситуация предыдущей.

7.1 Функционал качества оценки вероятности

В случае поведения вашей модели по сценарию **patologic +1 bias** или **patologic -1 bias** скорее всего вашему решению мало что поможет, кроме как смены архитектуры или рассматриваемой модели данных. Однако в остальных случаях есть шанс поднастроить модель, ”просмотреть паттерн ее ошибок и вручную изменить ей выходные оценки”. Семейство таких методов называется «калибровками». Для этого введем функционал качества калибровки **Expected/Maximum calibration error** по аналогии с диаграммой:

Обозначим $I_b = \{j : q(x_j) \in \mathbb{B}_b\}$, $n_b = |I_b|$ и

$$\bar{p}_b = \frac{1}{n_b} \sum_{j \in I_b} q(x_j), \quad \bar{y}_b = \frac{1}{n_b} \sum_{j \in I_b} \mathbf{1}_{\{k_j = +1\}}.$$

Тогда

$$\text{ECE} = \sum_{b: n_b > 0} \frac{n_b}{N} |\bar{p}_b - \bar{y}_b|, \quad \text{MCE} = \max_{b: n_b > 0} |\bar{p}_b - \bar{y}_b|.$$

Пустые бины исключаем. ECE усредняет отклонения с учётом числа объектов, а MCE показывает наибольшее отклонение среди непустых бинов.

Эти метрики используют прежде всего для оценки качества на независимой выборке. Прямая оптимизация затруднена из-за жёсткого разбиения на бины и негладкости функционала. Значения зависят от границ бинов и объёма выборки; изменение правой части само по себе не запрещает оптимизацию.

7.2 Методы калибровки вероятностей

Методы калибровки предлагают не изменять модель напрямую. Напротив, они фиксируют веса модели, в то же время используя ее выход как новый признак объектов, что в теории позволяет усложнить модель и сделать ее более ”нелинейной”. Более того, в таком случае мы получаем возможность сделать вероятностную модель из не вероятностной. Всего существует 3 наиболее применимых и популярных подхода:

- **Калибровка Платта** – самая очевидная и широко применяемая, основанная на ”логистической регрессии” поверх выхода классификатора.
- **Isotonic regression** – классическая задача восстановления функции распределения поверх стратегии q через изотоническую регрессию.
- **Гистограммная калибровка** – упрощенный вариант изотонической регрессии, с фиксированными границами $\mathbb{B}_i$

7.2.1 Калибровка Платта

Калибровка Платта первоначально предложена для получения вероятностей из отступов моделей, в частности SVM. Обозначим через $s_i = s(x_i)$ фиксированную выходную оценку исходного классификатора (например, отступ или логит). Калибратор представляет собой логистическую регрессию с одним признаком:

$$p_{\text{cal}}(k_i = +1 | x_i) = \sigma(\alpha s_i + \beta) = \frac{1}{1 + \exp\{-\alpha s_i - \beta\}}.$$

Параметры α и β определяют масштаб и сдвиг. Их обучаем по размеченной калибровочной выборке, минимизируя отрицательный логарифм правдоподобия:

$$\sum_{i=1}^N \log(1 + \exp\{-k_i(\alpha s_i + \beta)\}) \longrightarrow \min_{\alpha, \beta \in \mathbb{R}}, \quad k_i \in \{-1, +1\}.$$

Метки k_i определяют, какую вероятность следует увеличивать для каждого объекта. Веса исходного классификатора фиксируем; калибратор обучаем на данных, не использованных для обучения исходной модели, а результат оцениваем на отдельной тестовой выборке.

Усложнение модели Платта: вместо сигмиды можно использовать какую-нибудь другую функцию, дающую на выходе число от 0 до 1, например функцию плотности бета распределения (рис. 6):

$$p(q(x) | k = +1, \alpha_1, \beta_1) = \mathcal{B}(q(x), \alpha_1, \beta_1) = \frac{q(x)^{\alpha_1-1} (1 - q(x))^{\beta_1-1}}{\mathcal{B}(\alpha_1, \beta_1)}$$

$$p(q(x) | k = -1, \alpha_2, \beta_2) = \mathcal{B}(q(x), \alpha_2, \beta_2) = \frac{q(x)^{\alpha_2-1} (1 - q(x))^{\beta_2-1}}{\mathcal{B}(\alpha_2, \beta_2)}$$

Руководствуясь леммой Неймана-Пирсона, найдем отношение плотностей вероятности и обучим параметры на максимум правдоподобия:

$$LR = \frac{q(x)^{\alpha_1-1} (1 - q(x))^{\beta_1-1}}{q(x)^{\alpha_2-1} (1 - q(x))^{\beta_2-1}} \cdot \frac{\mathcal{B}(\alpha_2, \beta_2)}{\mathcal{B}(\alpha_1, \beta_1)} = \frac{q(x)^a}{(1 - q(x))^b} K \simeq \frac{q(x)^a}{(1 - q(x))^b} e^{-c}$$

Здесь мы приблизили отношение Бета функций экспонентой. Теперь же превратим отношение правдоподобия в вероятность, $a \geq 0$, $b \geq 0$, и получим классический вид **Бета калибровки**:

$$p(k = +1 | q(x), a, b, c) = \frac{1}{1 + LR^{-1}} = \frac{1}{1 + e^c / \frac{q(x)^a}{(1-q(x))^b}}$$




Рис. 6: Примеры $\mathcal{B}$ распределений

7.2.2 Калибровка Isotonic regression

Строится монотонно неубывающая кусочно-постоянная функция деформации оценок алгоритма (рис. 7). Требуется восстановить функцию $g(q(x))$, параметрами которой является измельчение сегмента $[0, 1]$, на каждом сегменте измельчения $g(t) = \text{const}$, $g(t_1) \leq g(t_2)$, $t_1 \leq t_2$, что в общем случае решается специальными солверами (например pool adjacent violators algorithm за $O(n)$).

$$\sum_{i=1}^N (k_i - g(q(x_i)))^2 \longrightarrow \min_g$$

7.2.3 Гистограммная калибровка

Является частным случаем Изотонической при фиксированных равных интервалах $\mathbb{B}_i$. Такой метод предсказывает лишь конечное число вероятностей, являющееся гиперпараметром алгоритма.

$$\sum_{i=1}^{\ell} \left| \frac{1}{|\mathbb{B}_i|} \sum_{j=1}^N \mathbf{1}_{\{q(x_i) \in \mathbb{B}_i\}} k_j - \theta_i \right| \longrightarrow \min_{\vec{\theta}}$$




Рис. 7: Определение Изотонической калибровки

1. https://github.com/mmp-mmro-team/mmp_mmro_fall_2024/blob/main/seminars/Seminar_5_probabalistic_ml.pdf
2. Десять лекций по статистическому и структурному распознаванию образов. Михаил Иванович Шлезингер, Вацлав Главач
3. McCullagh P., Nelder J. A. *Generalized Linear Models*. 2nd ed. Chapman & Hall, 1989. Разделы 2.2 и 4.2–4.4.
4. <https://education.yandex.ru/handbook/ml/article/kak-ocenivat-veroyatnosti>
5. Beyond sigmoids: How to obtain well-calibrated probabilities from binary classifiers with beta calibration