Негладкая и условная оптимизация

Введение в условную оптимизацию и её приложения к ML

Оглавление

1 Где в ML возникает негладкая и условная оптимизация? . . . 1
2 Переход от негладкой задачи к задаче с ограничениями . . . 1
3 Необходимые условия локального минимума . . . 1
3.1 Проблемы безусловного необходимого условия . . . 1
3.2 Необходимое условие условного локального минимума . . . 3
3.3 Теорема Каруша-Куна-Таккера (KKT) . . . 3
4 Лагранжева двойственность . . . 11
5 Приложения к задачам ML . . . 12
5.1 Lasso и l_1 регуляризация . . . 12
5.2 SVM и kernel trick . . . 14
5.3 Kernel trick . . . 16
5.4 Kernel trick в LogReg . . . 16
6 Задачи . . . 17
7 (Доп. материал) Субдифференциалы негладких выпуклых функций . . . 17
8 (Доп. материал) Fenchel duality и сопряженные функции . . . 17

Богачев Владимир @bogachevvTG

Лекция 06, осень 2026

1 Где в ML возникает негладкая и условная оптимизация?

TODO: Написать

2 Переход от негладкой задачи к задаче с ограничениями

В предыдущем разделе мы рассмотрели примеры задач негладкой оптимизации в ML: l_1 регуляризация и *SVM*. В данном разделе мы разберёмся как перейти от задачи негладкой оптимизации к более удобной для анализа (доступными нам методами) задаче условной оптимизации.

Пример 2.1: Пример перехода от негладкой задачи к гладкой условной задаче

Рассмотрим задачу $f(x) := |x| \to \min\limits_{x \in \mathbb{R}}$. Функция $f(x) \notin \mathrm{C}^1(\mathbb{R})$. Так как $|x| = \max\{x, -x\}$, то задача будет эквивалентна

$$\begin{aligned} & t \to \min\limits_{x,t \in \mathbb{R}} \\ \texttt{s.t.} \quad & x \leqslant t \\ & -x \leqslant t \end{aligned}$$

TODO: Вставить иллюстрацию

В большинстве практических задач мы можем вручную найти способ перехода от негладкой задачи $f(x) \to \min\limits_{x \in R^n}$ для выпуклой функции $f(x)$ к условной задаче

$$\begin{aligned} & f(x) \to \min \\ \texttt{s.t.} \quad & \psi_j(x) = 0 \quad \forall j = 1, \dots, p \\ & \varphi_i(x) \leqslant 0 \quad \forall i = 1, \dots, m \end{aligned}$$

где все функции $f, \psi_j, \varphi_i \in \mathrm{C}^1(\mathbb{R}^n)$.

Возможность такого перехода обеспечивает следующий приём TODO: Написать доп. материал

3 Необходимые условия локального минимума

Далее будем рассматривать задачу

$$\begin{aligned} & f(x) \to \min \\ \texttt{s.t.} \quad & \psi_j(x) = 0 \quad \forall j = 1, \dots, p \\ & \varphi_i(x) \leqslant 0 \quad \forall i = 1, \dots, m \end{aligned}$$

3.1 Проблемы безусловного необходимого условия

В гладких безусловных задачах $f(x) \to \min\limits_{x \in \mathbb{R}^n}$ необходимым условием будет $\nabla f(x_*) = 0$. Но в условной задаче условие $\nabla f(x_*) = 0$ **не является необходимым**.

Пример 3.1: Пример условного минимума

Рассмотрим задачу

$$f(x) \to \min$$
$$\texttt{s.t.} \quad x \in D$$

для $D = (-\inf, 1]$ и $D = [1, +\inf)$.



Рис. 1. Пример условного минимума

В случае $D = (-\inf, 1]$ точка $x_* = 0$ является минимумом и условие $\nabla f(x_*) = 0$ выполняется.
В случае $D = [1, +\inf)$ точка $x_* = 1$ является минимумом и условие $\nabla f(x_*) = 0$ **не выполняется**.

Для понимания проблем безусловного варианта вспомним доказательство необходимости данного условия.

Теорема 3.2: Необходимое условие в задаче без ограничений

Пусть $f(x) \in C^1(\mathbb{R}^n)$ и x_* — локальный минимум, тогда с необходимостью выполняется условие $\nabla f(x) = 0$.

Доказательство. По определению локального минимума, найдется некоторая окрестность $B_\varepsilon(x_*)$ точки x_* в которой $f(x) \geqslant f(x_*) \forall x \in B_\varepsilon(x_*)$.

Докажем от противного. Если $\nabla f(x_*) \neq 0$, то рассмотрим точку $x = x_* - \gamma \nabla f(x_*)$. Так как $\nabla f(x_*) \neq 0$, то $x \neq x_*$. Коэффициент γ можно выбрать достаточно малым для $x \in B_\varepsilon(x_*)$.

Тогда $f(x) = f(x_*) + \langle \nabla f(x_*), x - x_* \rangle + \overline{o}(\gamma) = f(x_*) + \langle \nabla f(x_*), -\gamma \nabla f(x_*) \rangle + \overline{o}(\gamma) = f(x_*) - \gamma \|\nabla f(x_*)\|^2 + \overline{o}(\gamma)$. При выборе достаточно малого γ получим противоречие $f(x) < f(x_*)$.

Данное размышление проиллюстрировано на рис. 2 ∎

В данном доказательстве мы неявно опирались на следующее предположение: если $x_* \in D$, то $B_\varepsilon(x_*) \subset D$. Другими словами, из тестируемой точки мы можем сделать малый шаг **в любом** направлении. Но в условной задаче это предположение может оказаться неверно!

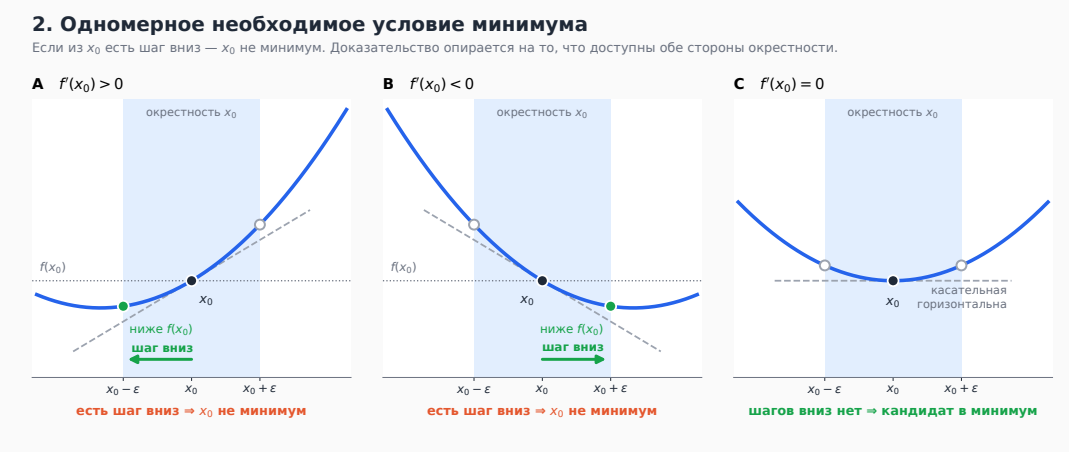


Рис. 2. Доказательство необходимости условия локального минимума

3.2 Необходимое условие условного локального минимума

В прошлом разделе мы столкнулись с проблемой, что в условной задаче не любое направление может оказаться допустимым, поэтому привычное условие локального минимума перестаёт быть необходимым.

Теорема 3.3: Необходимое условие локального минимума

Пусть $D \subset \mathbb{R}^n$, $f \in \mathrm{C}^1(D)$. Пусть $x_* \in D$ — условный локальный минимум, тогда с необходимостью выполняется следующее условие: для любой гладкой кривой $\gamma(t) \in D, \gamma(0) = x_*$ будет выполнено $\langle \nabla f, \dot{\gamma}(0) \rangle \geqslant 0$.

Доказательство. По определению локального условного минимума, найдется окрестность $V = B_\varepsilon(x_*) \cap D$ точки x_*, в которой $f(x) \geqslant f(x_*) \forall x \in V$. Тогда рассмотрим произвольную кривую $\gamma(t) \in V, \gamma(0) = x_*$. Тогда точка 0 будет безусловным локальным минимумом функции $\varphi(t) = f(\gamma(t))$. Для данной функции необходимым условием будет $\frac{d}{dt}\varphi(t) \mid_0 = 0$. Следовательно, с необходимостью выполняется условие $\frac{d}{dt}\varphi(t) = \langle \nabla f, \dot{\gamma}(0) \rangle = 0$. ∎

Данное условие является необходимым, но проверять его крайне тяжело. Поэтому нужно найти более удобную для проверки формулировку.

3.3 Теорема Каруша-Куна-Таккера (KKT)

Рассмотрим задачу условной оптимизации

$$\begin{aligned} & f(x) \to \min \\ \texttt{s.t.} \quad & \psi_j(x) = 0 \quad \forall j = 1, \ldots, p\,. \\ & \varphi_i(x) \leqslant 0 \quad \forall i = 1, \ldots, m \end{aligned} \tag{1}$$

Теорема 3.4: Теорема Каруша-Куна-Таккера (KKT)

Пусть $f, \varphi_i, \psi_j \in C^1(\mathbb{R}^n)$, пусть точка x_* является условным локальным минимумом (1). Пусть задача (1) является регулярной (подробнее в подразделе 3.3.1). Рассмотрим

функцию

$$\mathcal{L}(x, \lambda, \mu) = f(x) + \sum_i \lambda_i \varphi_i(x) + \sum_j \mu_j \psi_j(x)$$

Тогда найдутся $\mu^* \in \mathbb{R}^p, \lambda^* \in \mathbb{R}^m_+$, для которых будут выполнены условия

1. **Стационарность** $\nabla_x \mathcal{L}(x_*, \lambda^*, \mu^*) = 0$;
2. **Прямая допустимость** $\varphi_i(x_*) \leqslant 0 \quad \forall i = 1, \ldots, m$ и $\psi_j(x_*) = 0 \quad \forall j = 1, \ldots, p$;
3. **Двойственная допустимость** $\lambda_i^* \geqslant 0 \quad \forall i = 1, \ldots, m$;
4. **Дополняющая нежёсткость** $\lambda_i^* \varphi_i(x_*) = 0 \quad \forall i = 1, \ldots, m$.

Доказательство. Пусть x_* — условный локальный минимум задачи (1). Тогда для любой гладкой кривой $\gamma(t) \in B_\varepsilon(x_*) \cap D,\ \gamma(0) = x_*$ будет выполнено $\langle \nabla f(x_*), \dot{\gamma}(0) \rangle \geqslant 0$.

Получим явное описание множества $T_{x_*}(D) = \{\dot{\gamma}(0) \mid \gamma(t) \in B_\varepsilon(x_*) \cap D,\ \gamma(0) = x_*\}$. Подставим $\gamma(t)$ в ограничения.

Для ограничения типа равенства будет выполняться $\psi_j(\gamma(t)) \equiv 0$, следовательно, $\frac{d}{dt}\psi_j(\gamma(t)) = \langle \nabla \psi_j(x_*), \dot{\gamma}(0) \rangle = 0$.

Для ограничений типа неравенств необходимо рассмотреть два случая. Если $\varphi_i(x_*) < 0$, то найдется окрестность $B_\varepsilon(x_*) \cap D$ в которой $\varphi_i(x) < 0$. Следовательно, ограничение допускает любой малый шаг. Другими словами, $\forall \gamma(t) \in B_\varepsilon(x_*) \cap D, \gamma(0) = x_*$ будет выполнено $\varphi_i(\gamma(t)) < 0$. Если же $\varphi_i(x_*) = 0$, то $\varphi_i(\gamma(t)) \leqslant \varphi_i(\gamma(0)) = 0$, следовательно, $\frac{d}{dt}\varphi_i(\gamma(t)) = \langle \nabla \varphi_i, \dot{\gamma}(0) \rangle \leqslant 0$.

Далее будем называть ограничения φ_i активными в точке x, если неравенство обращается в равенство $\varphi_i(x) = 0$. Множество индексов активных ограничений в точке x обозначим $J(x)$.

Таким образом, мы получили описание векторов скоростей $\dot{\gamma}(0)$ допустимых гладких кривых. Обозначим

$$K = \left\{ \zeta \in \mathbb{R}^n \;\middle|\; \begin{array}{ll} \langle \nabla \psi_j(x_*), \zeta \rangle = 0, & j = 1, \ldots, p, \\ \langle \nabla \varphi_i(x_*), \zeta \rangle \leqslant 0, & i \in J(x_*) \end{array} \right\}.$$

На рис. 3 проиллюстрированы случаи одного ограничения типа неравенства (рис. 3.1) и равенства (рис. 3.2).

Мы убедились, что любое допустимое направление не должно в первом порядке нарушать ограничения, поэтому $T_{x_*}(D) \subset K$. Обратное включение в общем случае неверно. Обратное включение обеспечивают условия регулярности. Подробнее об условиях регулярности будет рассказано в подразделе 3.3.1.

Условия регулярности обеспечивают $T_{x_*}(D) = K$, поэтому необходимое условие оптимальности принимает вид

$$\langle \nabla f(x_*), \zeta \rangle \geqslant 0 \quad \forall \zeta \in K. \tag{2}$$

На рисунке 4 проиллюстрированы примеры $T_{x_*}(D) = K$ и $T_{x_*}(D) \subsetneq K$.

Рассмотрим случай одного ограничения типа равенства $D = \{x \mid \psi(x) = 0\}$. Тогда $K = \{\zeta \in \mathbb{R}^n \mid \langle \nabla \psi, \zeta \rangle = 0\}$ — гиперплоскость в $\mathbb{R}^n$. Покажем, что в таком случае $\nabla f \parallel \nabla \psi$.

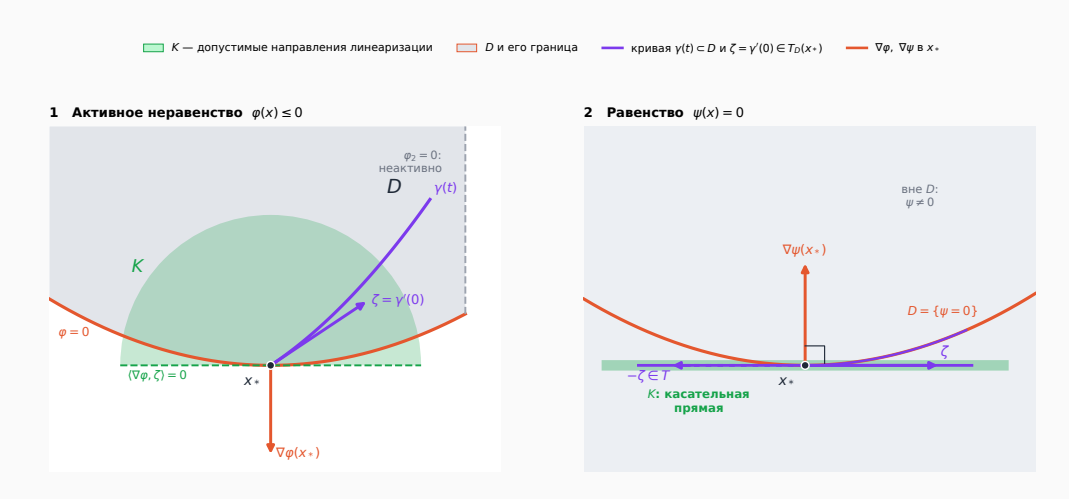


Рис. 3. Вложенность $T_{x_*}(D) \subset K$

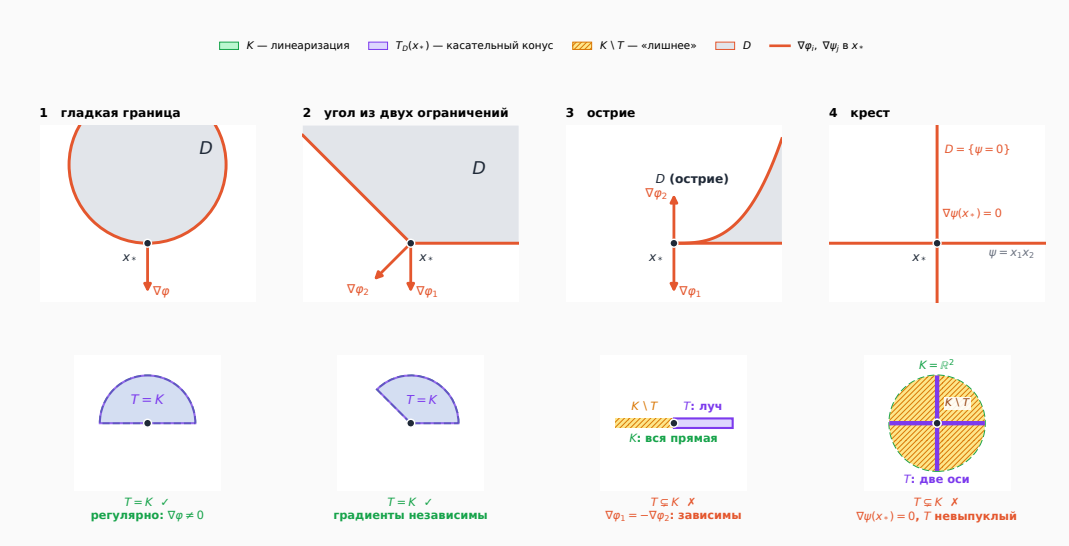


Рис. 4. Иллюстрация $T_{x_*}(D) = K$ и $T_{x_*}(D) \subsetneq K$.

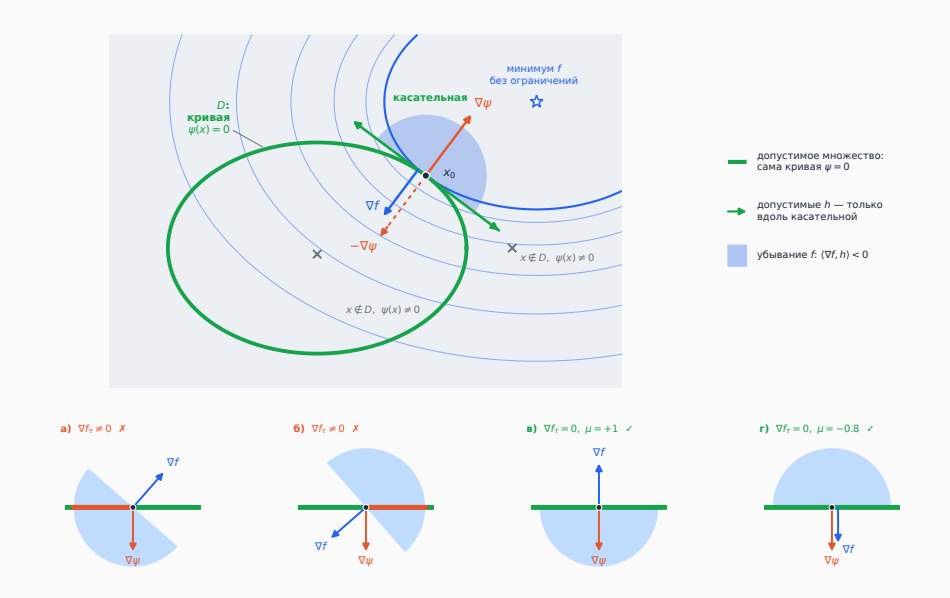


Рис. 5. Иллюстрация необходимого условия для случая одного ограничения типа равенства

Если это не так, то $\nabla f = \alpha\nabla\psi + \xi$, где $\xi \perp \nabla\psi$. Из $\xi \perp \nabla\psi$ следует, что $\xi \in K$. Так как K — гиперплоскость, то и $-\xi \in K$. Следовательно

$$\langle \nabla f, -\xi \rangle = \langle \alpha\psi + \xi, -\xi \rangle = \langle \xi, -\xi \rangle < 0.$$

Получаем противоречие, следовательно, $\nabla f \parallel \nabla\psi$. На рисунке 5 иллюстрируется данное размышление.

Аналогичные рассуждения позволяют показать, что для случая

$$D = \{x \in \mathbb{R}^n \mid \psi_1(x) = \ldots = \psi_p(x) = 0\}$$

условие (2) превращается в $\nabla f \in \text{Span}(\nabla\psi_1, \ldots, \nabla\psi_p)$. Следовательно, найдутся $\mu_1, \ldots, \mu_p \in \mathbb{R}$ такие что

$$\nabla f(x_*) + \mu_1\nabla\psi_1(x_*) + \ldots + \mu_p\nabla\psi_p(x_*) = 0.$$

Теперь рассмотрим случай одного ограничения типа неравенство $D = \{x \mid \varphi(x) \leqslant 0\}$. Тогда $K = \{\zeta \mid \langle \nabla\psi, \zeta \rangle \leqslant 0\}$. Тогда условие (2) приводит к $-\nabla f \uparrow\uparrow \nabla\psi$. Рис. **??** иллюстрирует данный пример. Пусть $\nabla f = \alpha\nabla\psi + \xi$, где $\xi \perp \nabla\psi$. Тогда $\xi, -\xi \in K$. Тогда из $\langle \nabla f, -\xi \rangle = \langle \xi, -\xi \rangle \geqslant 0$ следует $\xi = 0$. Так как $\langle \nabla\varphi, -\nabla\varphi \rangle \leqslant 0$, то вектор $-\nabla\varphi \in K$. Тогда из условия $\langle \alpha\nabla\varphi, -\nabla\varphi \rangle \geqslant 0$ получим $\alpha \leqslant 0$. Следовательно, $-\nabla f \uparrow\uparrow \nabla\psi$. Другими словами, $\exists\lambda \geqslant 0\colon\ \nabla f + \lambda\nabla\varphi = 0$. TODO: Сослаться на 6

Для случая нескольких активных ограничений условие $\langle \nabla f, \zeta \rangle \geqslant 0 \quad \forall\zeta \in K$ приводит к $\exists\lambda_i \geqslant 0\ \forall i \in J(x_*)\colon \nabla f + \sum_{i\in J(x_*)} = 0$. Данное утверждение является леммой Фаркаша 3.3. TODO: Сослаться на 7

Таким образом, в общем случае найдутся $\mu_1, \ldots, \mu_p \in R$ и $\lambda_i \geqslant 0, i \in J(x_*)$ такие что

$$\nabla f + \sum_{i\in J(x_*)} \lambda_i\nabla\varphi_i + \sum_j \mu_j\nabla\psi_j = 0.$$

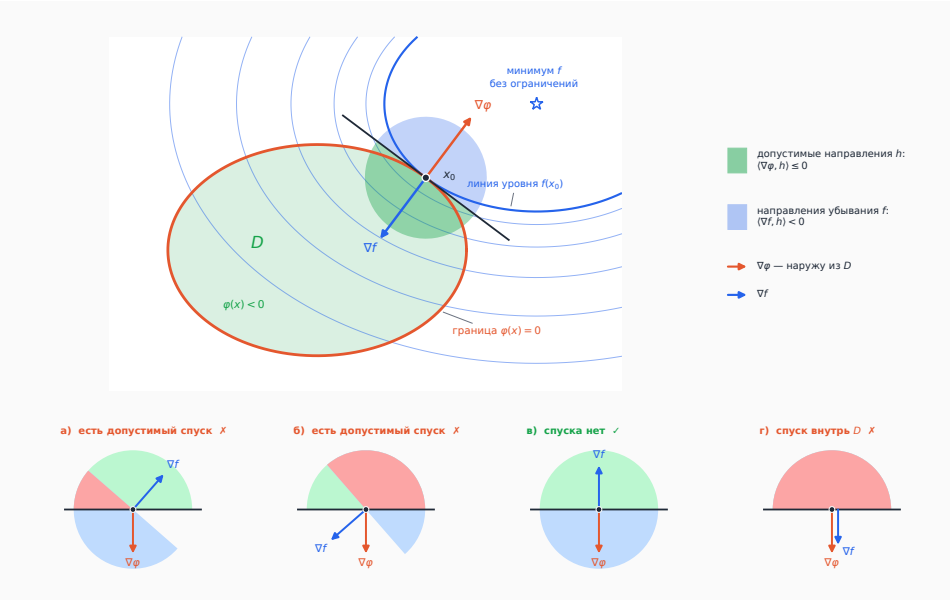


Рис. 6. Иллюстрация необходимого условия для случая одного ограничения типа неравенства

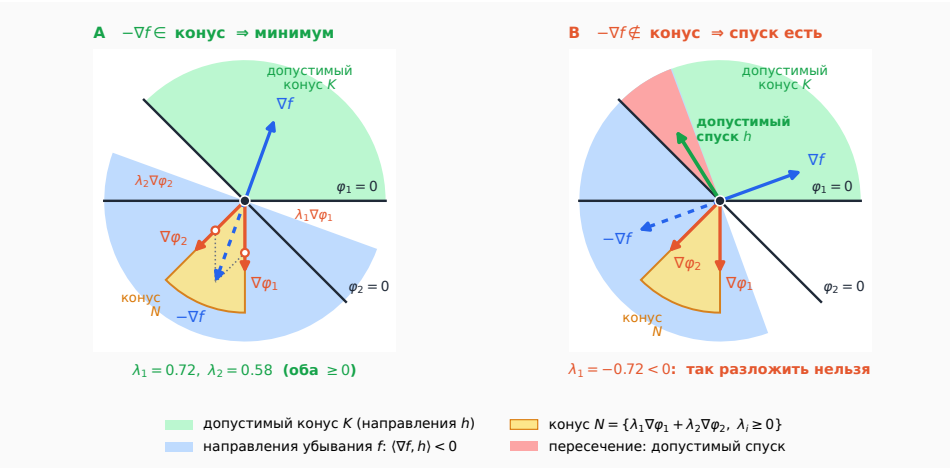


Рис. 7. Иллюстрация необходимого условия для случая двух ограничений типа неравенства

Положим $\lambda_i := 0 \; \forall i \notin J(x_*)$, тогда

$$\nabla_x \mathcal{L} = \nabla f + \sum_i \lambda_i \nabla \varphi_i + \sum_j \mu_j \nabla \psi_j = 0.$$

Условие $\lambda_i := 0 \; \forall i \notin J(x_*)$ превращается в условие дополняющей нежёсткости $\lambda_i \varphi_i(x_*) = 0 \quad \forall i = 1, \ldots, m$.

■

Определение 3.5: Выпуклая задача

Задача $f(x) \to \min_{x \in D}$ называется выпуклой, если D — выпуклое множество, а $f(x)$ — выпуклая функция на D.
Если задача имеет вид

$$\begin{aligned} & f(x) \to \min \\ \texttt{s.t.} \quad & \psi_j(x) = 0 \quad \forall j = 1, \ldots, p \\ & \varphi_i(x) \leqslant 0 \quad \forall i = 1, \ldots, m \end{aligned}$$

то выпуклость D обеспечивается выпуклостью всех φ_i и аффинностью $\psi_j(x)$ (другими словами $\psi_j(x) = \langle w_j, x \rangle + b_j$).

Замечание 3.6: Достаточные условия условного оптимума

Если задача (1) является **выпуклой**, то условия теоремы ККТ 3.3 являются не только необходимыми, но и достаточными!
В курсе классического машинного большинство постановок задач являются выпуклыми. Невыпуклая оптимизация появится в курсе глубокого обучения.

В доказательстве теоремы ККТ использовалась лемма об отделимости.

Лемма 3.7: (Доп. материал) Лемма об отделимости (лемма Фаркаша)

Пусть $K \subset \mathbb{R}^n$ — выпуклый замкнутый конус, т.е. K замкнуто, выпукло и $\alpha\zeta \in K$ для всех $\zeta \in K$, $\alpha > 0$ (при $K \neq \varnothing$ отсюда $0 \in K$ по замкнутости). Двойственный конус определим как

$$K^* = \{\eta \in \mathbb{R}^n \mid \langle \eta, \zeta \rangle \geqslant 0 \;\; \forall \zeta \in K\}.$$

1. **(Отделимость точки от конуса.)** Если $x \notin K$, то существует $s \in \mathbb{R}^n$ такой, что

$$\langle s, x \rangle < 0 \leqslant \langle s, \zeta \rangle \quad \forall \zeta \in K,$$

   т.е. $s \in K^*$ и $\langle s, x \rangle < 0$.
2. **(Лемма Фаркаша.)** Пусть $a_1, \ldots, a_m \in \mathbb{R}^n$ и $K = \operatorname{cone}\{a_1, \ldots, a_m\} = \left\{\sum_{i=1}^m \lambda_i a_i \mid \lambda_i \geqslant 0\right\}$. Тогда K является выпуклым замкнутым конусом, и для любого $g \in \mathbb{R}^n$ выполнено ровно одно из двух:
   (A) существуют $\lambda_1, \ldots, \lambda_m \geqslant 0$ такие, что $g = \sum_{i=1}^m \lambda_i a_i$;
   (B) существует $\zeta \in \mathbb{R}^n$ такой, что $\langle a_i, \zeta \rangle \geqslant 0$ для всех $i = 1, \ldots, m$ и $\langle g, \zeta \rangle < 0$.

Эквивалентная формулировка:

$$\big(\langle a_i, \zeta\rangle \geqslant 0 \ \ \forall i \implies \langle g, \zeta\rangle \geqslant 0\big) \iff g \in \operatorname{cone}\{a_1, \dots, a_m\}.$$

Замечание 3.8: (Доп. материал)

Множество K называется конусом, если $\forall \zeta \in K, \forall \alpha > 0 \Rightarrow \alpha\zeta \in K$. Конусы играют очень важную роль в выпуклой оптимизации.
Множество

$$K = \left\{ \zeta \in \mathbb{R}^n \;\middle|\; \begin{array}{ll} \langle \nabla\psi_j(x_*), \zeta\rangle = 0, & j = 1, \dots, p, \\ \langle \nabla\varphi_i(x_*), \zeta\rangle \leqslant 0, & i \in J(x_*) \end{array} \right\}.$$

является конусом, а множество

$$K^* = \{\eta \in \mathbb{R}^n \mid \langle \eta, \zeta\rangle \geqslant 0 \quad \forall \zeta \in K\}$$

называется двойственным (или сопряженным) конусом к K.
Утверждение $K^* = \left\{\sum_i -\lambda_i \nabla\varphi_i + \sum_j \mu_j \nabla\psi_j \mid \lambda_i \geqslant 0, \mu_j \in \mathbb{R}\right\}$ является переформулировкой леммы Фаркаша TODO: cite

Замечание 3.9: Сложность проверки необходимых условий

В безусловной гладкой задаче $f(x) \to \min_{x\in\mathbb{R}^n}$ необходимым условием было $\nabla f(x) = 0$. Данное условие является $n \times n$ системой нелинейных уравнений на x. Решение задачи оптимизации сводилось к решению данной системы (либо аналитически, либо численно).
В условной задаче (1) необходимые условия 3.3 дают следующую систему из $n+m+p$ уравнений и $2m$ неравенств на $n+m+p$ переменных:

$$\begin{cases} \nabla_x \mathcal{L}(x_*, \lambda^*, \mu^*) = 0 & \\ \psi_j(x_*) = 0 & \forall j = 1, \dots, p \\ \lambda_i^* \varphi_i(x_*) = 0 & \forall i = 1, \dots, m \\ \varphi_i(x_*) \leqslant 0 & \forall i = 1, \dots, m \\ \lambda_i^* \geqslant 0 & \forall i = 1, \dots, m \end{cases}$$

Наличие в системе уравнений вида $\lambda_i^* \varphi_i(x_*) = 0$ и неравенств делает поиск решения комбинаторной задачей. Для решения системы, зачастую, приходится перебирать случаи $\lambda_i = 0$ и $\lambda_i > 0$ для $\forall i = 1, \dots, m$. Поэтому проверка необходимых условий в (1), зачастую, оказывается более трудоёмкой, чем в гладкой безусловной задаче. В разделе 4 будет обсуждаться подход, позволяющий упростить проверку условий.

3.3.1 Регулярность задачи

В формулировке теоремы 3.3 фигурировало требование регулярности задачи. В процессе доказателсьва мы поняли, что регулярность заключается в $T_D(x_*) = K$. Другими словами, параметризация области D достаточно хорошая.

Пример 3.10: Пример нерегулярной задачи

Рассмотрим $D = \{x \mid x^2 \leqslant 0\}$. Очевидно, $D = \{0\}$. Тогда любая гладкая кривая $\gamma(t) \in D$ имеет вид $\gamma(t) \equiv 0$, следовательно, $T_D(0) = \{0\}$.
Теперь рассмотрим $K = \{\zeta \mid \langle \nabla\varphi(0), \zeta\rangle \leqslant 0\}$. Очевидно, что $\nabla\varphi(0) = 2x \mid_{x=0} = 0$, следовательно, $K = \mathbb{R}$.
Попробуем рассмотреть задачу $f(x) := x \to \min_{x\in D}$ и проверить необходимые условия из теоремы ККТ 3.3. Выпишем $\mathcal{L}(x, \lambda) = f(x) + \lambda x^2$. Тогда из условия стационарности $0 = \nabla_x \mathcal{L}(x, \lambda) = 1 + 2\lambda x$. В единственной допустимой точке $\nabla\mathcal{L}(0, \lambda) = 1$. Следовательно, не найдется двойственной переменной $\lambda \geqslant 0$, удовлетворяющей необходимым условиям. Но точка $x_* = 0$, очевидно, является оптимумом $f(x) := x$ на D.

Проверить регулярность помогает следующая теорема

Теорема 3.11: Достаточные условия регулярности

Пусть $f, \varphi_i, \psi_j \in \mathrm{C}^1(\mathbb{R}^n)$. Тогда задача

$$\begin{aligned} & f(x) \to \min \\ \texttt{s.t.} \quad & \psi_j(x) = 0 \quad \forall j = 1, \dots, p \\ & \varphi_i(x) \leqslant 0 \quad \forall i = 1, \dots, m \end{aligned}$$

будет регулярной, если выполняется хотя бы одно из следующих условий.

Аффинность Если все φ_i, ψ_j — аффинные функции, то задача регулярна;

Линейная независимость градиентов Если в точке x_* градиенты $\nabla\psi_1(x_*), \dots, \nabla\psi_p(x_*), \nabla\varphi_{i\in J(x_*)}(x_*)$ линейно независимы, то задача регулярна.

Условие Слейтера Если задача выпукла (все f, φ_i выпуклы и ψ_j линейны) и область D имеет внутреннюю точку, т.е. $\exists x \in D\colon \psi_1(x) = \ldots = \psi_m(x) = 0, \varphi_1(x), \dots, \varphi_m(x) < 0$, то задача является регулярной.

Ослабленное условие слейтера Аналогично условию Слейтера, но требование $\varphi_i(x) < 0$ накладывается только на **нелинейные** ограничения $\varphi_i(x) \leqslant 0$. В линейных ограничениях может быть равенство.

Пример 3.12: Пример регулярной задачи

Рассмотрим $D = \{x \mid x \leqslant 0, -x \leqslant 0\}$. Очевидно, $D = \{0\}$. Теперь проверим 4 условия регулярности:

1. **Аффинность** Все ограничения линейны, следовательно задача регулярна;
2. **Линейная независимость градиентов** Не выполняется, так как градиенты $\nabla\varphi_1 = +1, \nabla\varphi_2 = -1$ линейно зависимы;
3. **Условие Слейтера** Не выполняется, так как в точке $x = 0$ оба неравества обращаются в равенство;
4. **Ослабленное условие Слейтера** Выполняется, так как все ограничения линейные;

Таким образом, условия в 3.3.1 являются достаточными, но не необходимыми.

4 Лагранжева двойственность

Рассмотрим гладкую задачу с ограничениями типа равенств:

$$\begin{gathered} f(x) \to \min\limits_x \\ \texttt{s.t.} \quad \psi_j(x) = 0 \quad \forall j = 1, \ldots, p \end{gathered}.$$

В данной задаче необходимые условия оптимума имеют вид

$$\begin{cases} \mathcal{L}(x, \mu) = f(x) + \sum_j \mu_j \psi_j(x) \\ \nabla_x \mathcal{L}(x_*, \mu^*) = 0 \\ \nabla_\mu \mathcal{L}(x_*, \mu^*) = 0 \end{cases}.$$

Следовательно, точка (x_*, μ^*) является стационарной для функции $\mathcal{L}(x, \lambda)$. Покажем, что в задаче с ограничениями типа равенств и неравенств точка (x_*, λ^*, μ^*) тоже является стационарной.

Пусть в точке (x_*, λ^*, μ^*) выполняются необходимые условия, тогда

$$\begin{cases} \nabla_x \mathcal{L}(x_*, \lambda^*, \mu^*) = 0 \\ \nabla_\mu \mathcal{L}(x_*, \lambda^*, \mu^*) = 0 \\ \frac{\partial}{\partial \lambda_i} \mathcal{L}(x_*, \lambda^*, \mu^*) = \varphi_i(x_*) \end{cases}.$$

Если неравенство обращается в равенство $\varphi_i(x_*) = 0$, то $\frac{\partial}{\partial \lambda_i} \mathcal{L}(x_*, \lambda^*, \mu^*) = 0$. Если ограничение выполняется строго $\varphi_i(x_*) < 0$, то двойственная переменная $\lambda_i^* = 0$ принадлежит границе допустимого множества $\lambda_i \geqslant 0$. Следовательно, точка (x_*, λ^*, μ^*) являетя условной стационарной. Данный факт наводит на мысль проверить, к какому типу (минимум
максимум
седловая точка) принадлежит точка (x_*, λ^*, μ^*).

Рассмотрим

$$\sup_{\substack{\lambda \geqslant 0 \\ \mu}} \mathcal{L}(x, \lambda, \mu) = f(x) + \sum_i \inf_{\lambda_i \geqslant 0} \lambda_i \varphi_i(x) + \sum_j \inf_{\mu_j \in \mathbb{R}} \mu_j \psi_j(x) =$$

$$= \begin{cases} f(x) & x \in D \\ +\infty & x \notin D \end{cases}$$

Тогда задача $f(x) \to \min_{x \in D}$ равносильна задаче

$$\inf_{x \in \mathbb{R}^n} \sup_{\substack{\lambda \geqslant 0 \\ \mu}} \mathcal{L}(x, \lambda, \mu)$$

Следовательно, точка (x_*, λ^*, μ^*) является седловой точкой $\mathcal{L}(x, \lambda, \mu)$.

Известно, что $\sup_x \inf_y F(x, y) \leqslant \inf_y \sup_x F(x, y)$, поэтому

Предложение 4.1: Седловая точка функции $\mathcal{L}$

Для функции Лагранжа $\mathcal{L}(x, \lambda, \mu)$ и стационарной точки (x_*, λ^*, μ^*) будет верно:

1. $\sup\limits_{\substack{\lambda \geqslant 0 \\ \mu}} \inf\limits_{x \in \mathbb{R}^n} \mathcal{L}(x, \lambda, \mu) \leqslant \inf\limits_{x \in \mathbb{R}^n} \sup\limits_{\substack{\lambda \geqslant 0 \\ \mu}} \mathcal{L}(x, \lambda, \mu)$
2. $\forall \mu, \forall \lambda \geqslant 0 \quad \mathcal{L}(x_*, \lambda, \mu) \leqslant \mathcal{L}(x_*, \lambda^*, \mu^*) \leqslant \mathcal{L}(x_*, \lambda, \mu) \leqslant \mathcal{L}(x, \lambda^*, \mu^*) \quad \forall x$

Предложение 4.2: Зазор двойственности

Величина $\delta = \inf\limits_{x \in \mathbb{R}^n} \sup\limits_{\substack{\lambda \geqslant 0 \\ \mu}} \mathcal{L}(x, \lambda, \mu) - \sup\limits_{\substack{\lambda \geqslant 0 \\ \mu}} \inf\limits_{x \in \mathbb{R}^n} \mathcal{L}(x, \lambda, \mu)$ называется зазором двойственности.

Для выпуклой задачи зазор двойственности $\delta = 0$.

Наблюдение 4 и предложение 4 мотивируют рассмотреть задачу

$$g(\lambda, \mu) := \inf_{x \in \mathbb{R}^n} \mathcal{L}(x, \lambda, \mu)$$
$$g(\lambda, \mu) \to \max_{\substack{\lambda \geqslant 0 \\ \mu}}$$

Данная задача, зачастую, оказывается проще исходной прямой задачи $f(x) \to \min_{x \in D}$.

Замечание 4.3: Вогнутость $g(\lambda, \mu)$

TODO: Написать

Замечание 4.4: (Доп. материал)

Утверждение 4 позволяют получить целый класс методов решения условных задач без перебора вида $\lambda_i = 0$ или $\lambda_i > 0 \quad \forall i = 1, \dots, m$.
Можно делать спуск по прямым перменным x и подъём по двойственным переменным $\lambda \geqslant 0, \mu$. Данные методы называются прямодвойственными. А зазор двойственности $\delta(x, \lambda, \mu)$ является показателем близости к оптимуму.

Ключевой проблемой перехода к двойственной задаче является восстановление оптимальной точки в прямой задаче x_* по решению двойственной задачи (λ^*, μ^*). Подробнее про решение данной проблемы рассказывается в дополнительных материалах TODO: вставить ссылку.

5 Приложения к задачам ML

5.1 Lasso и l_1 регуляризация

Рассмотрим задачу обучения Lasso regression

$$f(w) = \frac{1}{2}\|X^\top w - y\|^2 + \gamma \|w\|_1 \to \min_{w \in \mathbb{R}^d}.$$

Функция $\|w\|_1$ не является гладкой в точках w у которых $\exists i \colon w_i = 0$. Вам уже известно, что Lasso regression (в отличии от Ridge regression) отбирает признаки. Другими словами,

в оптимальном решении w_* часто $\exists i\colon (w_*)_i = 0$.

Решение через теорему ККТ. TODO: Попытка решить через ККТ

Решение через переход к двойственной задаче. Негладкость задачи мешала нам выписать необходимое условие оптимальности, поэтому мы переходили к условным задачам оптимизации. Но некоторые простые негладкие задачи мы можем решить не привлекая необходимых условий оптимальности. Рассматриваемая функция $f(w) = \frac{1}{2}\|X^\top w - y\|^2 + \gamma\|w\|_1$ состоит из двух "просто устроенных функций". Каждое слагаемое мы можем независимо проминимизировать, поэтому сложность задачи заключается во "взаимодействии"простых задач между собой. Рассмотрим другой подход к решению подобных задач. Исходная задача $f(w) = \frac{1}{2}\|X^\top w - y\|^2 + \gamma\|w\|_1 \to \min_w$ эквивалентна условной задаче

$$\begin{aligned} & \frac{1}{2}\|z\|^2 + \gamma\|w\|_1 \to \min_{x,z\in\mathbb{R}^d} \\ \texttt{s.t.} \quad & z = X^\top w - y \end{aligned}$$

Запишем $\mathcal{L}(w,z,\mu) = \frac{1}{2}\|z\|^2 + \gamma\|w\|_1 + \langle \mu, X^\top w - y - z\rangle$. Функция $\mathcal{L}(w,z,\mu)$ не является гладкой, поэтому мы не можем записать условие стационарности $\nabla_w \mathcal{L}(w,z,\mu) = 0, \nabla_z \mathcal{L}(w,z,\mu) = 0$. Однако, мы можем перейти к двойственной задаче

$$\begin{aligned} \mathcal{L}(w,z,\mu) &= \frac{1}{2}\|z\|^2 + \gamma\|w\|_1 + \langle \mu, X^\top w - y - z\rangle \\ &= \left(\frac{1}{2}\|z\|^2 - \langle \mu, z\rangle\right) + \left(\gamma\|w\|_1 + \langle \mu, X^\top w\rangle\right) - \langle \mu, y\rangle \\ \inf_{z,w\in\mathbb{R}^d} \mathcal{L}(w,z,\mu) &= \inf_{z\in\mathbb{R}^d}\left(\frac{1}{2}\|z\|^2 - \langle \mu, z\rangle\right) + \inf_{w\in\mathbb{R}^d}\left(\gamma\|w\|_1 + \langle \mu, X^\top w\rangle\right) - \langle \mu, y\rangle = \\ &= \inf_{z\in\mathbb{R}^d}\left(\frac{1}{2}\|z\|^2 - \langle \mu, z\rangle\right) + \sum_i \inf_{w_i\in\mathbb{R}} \left(\gamma\cdot|w_i| + w_i\cdot(X\mu)_i\right) - \langle \mu, y\rangle \end{aligned}$$

Причем двойственная задача разбилась на несколько простых подзадач по w и z.

Задачу $\inf_{z\in\mathbb{R}^d}\left(\frac{1}{2}\|z\|^2 - \langle \mu, z\rangle\right)$ мы можем решить, воспользовавшись необходимым условием оптимальности в безусловной гладкой задаче

$$0 = \nabla_z\left(\frac{1}{2}\|z\|^2 - \langle \mu, z\rangle\right) = z - \mu \quad \Longrightarrow \quad z = \mu$$

Задача по w распадается на d независимых негладких одномерных подзадач, каждую из которых мы можем решить аналитически. Рассмотрим функцию $h(w) = \gamma\cdot|w| + \alpha\cdot w$. Подставляя $\alpha = (X\mu)_i$ получим $h(w_i) = \gamma\cdot|w_i| + w_i\cdot(X\mu)_i$. На рисунке **??** изображены графики $h(w)$ при условии $|\alpha| < \gamma, |\alpha| = \gamma, |\alpha| > \gamma$ соответственно. Легко увидеть, что

$$\inf_w h(w) = \begin{cases} 0, & |\alpha| \leqslant \gamma \\ -\infty, & |\alpha| > \gamma \end{cases}$$

Следовательно, двойственная функция $g(\mu)$ имеет вид

$$g(\mu) = \begin{cases} -\frac{1}{2}\|\mu\|^2 - \langle \mu, y \rangle, & \|X\mu\|_\infty \leqslant \gamma \\ -\infty, & \|X\mu\|_\infty > \gamma \end{cases}$$

Тогда двойственная задача имеет вид

$$\begin{aligned} & -\frac{1}{2}\|\mu\|^2 - \langle \mu, y \rangle \to \max_{\mu} \\ \texttt{s.t.} \quad & \|X\mu\|_\infty \leqslant \gamma \end{aligned}$$

Предположим, что мы смогли найти решение двойственной задачи μ^*. Тогда из условия $z = \mu$ получаем, что $z_* = \mu^*$. Подставим $z_* = \mu^*$ в условие $z = X^\top w - y$ и получим уравнение на w:

$$X^\top w = \mu^* + y$$

Так как решение задачи $h(w) \to \min_w$ единственно при $|\alpha| < \gamma$, то мы знаем значения $(w_*)_i = 0$ при i для которых выполняется условие $|(X\mu^*)_i| < \gamma$. Следовательно, Lasso выполняет отбор признаков!

Замечание 5.1

Задача обучения Lasso не решается аналитически. Численные методы решения опираются на понятие субдифференциала и проксимального оператора TODO: вставить ссылку. Про численные методы решения негладких задач вы узнаете в весеннем семестре.

5.2 SVM и kernel trick

Рассмотрим теперь задачу обучения SVM

$$f(w, b) = \sum_i (1 - y_i(\langle w, x_i \rangle + b))_+ + \frac{1}{2}\|w\|^2 \to \min_{w,b}$$

Рассмотрим $(1 - y_i(\langle w, x_i \rangle + b))_+ = \max\{0, (1 - y_i(\langle w, x_i \rangle + b))\}$. Введём переменные $\xi_i = \max\{0, (1 - y_i(\langle w, x_i \rangle + b))\}$, тогда $\xi_i \geqslant 0$ и $\xi_i \geqslant 1 - y_i(\langle w, x_i \rangle + b)$. Тогда рассматриваемая задача будет эквивалентна условной задаче

$$\begin{aligned} & \frac{1}{2}\|w\|^2 + \sum_i \xi_i \to \min_{w,b,\xi} \\ \texttt{s.t.} \quad & \xi_i \geqslant 1 - y_i(\langle w, x_i \rangle + b) \quad \forall i = 1, \ldots, n \\ & \xi_i \geqslant 0 \qquad\qquad\qquad\qquad\quad \forall i = 1, \ldots, n \end{aligned}$$

Тогда

$$\begin{aligned}\mathcal{L}(w,b,\xi,\lambda,\eta) &= \frac{1}{2}\|w\|^2 + \sum_i \xi_i + \sum_{i=1}^n \lambda_i(1 - y_i(\langle w, x_i\rangle + b) - \xi_i) - \sum_{i=1}^n \eta_i\xi_i \\ &= \left(\frac{1}{2}\|w\|^2 - \sum_i \lambda_i y_i x_i^\top w_i\right) + \left(\sum_i \lambda_i y_i b\right) + \sum_i (\xi_i - \lambda_i\xi_i - \eta_i\xi_i) + \sum_i \lambda_i\end{aligned}$$

Отбор объектов. Тогда необходимыми условиями будут

$$\begin{cases}\nabla_w \mathcal{L} = w - \sum_{i=1}^n \lambda_i y_i x_i & \Longrightarrow \quad w = \sum_{i=1}^n \lambda_i y_i x_i & \text{Стационарность,} \\ \nabla_b \mathcal{L} = -\sum_{i=1}^n \lambda_i y_i & \Longrightarrow \quad \sum_{i=1}^n \lambda_i y_i = 0 & \text{Стационарность,} \\ \nabla_{\xi_i} \mathcal{L} = 1 - \lambda_i - \eta_i & \Longrightarrow \quad \lambda_i + \eta_i = 1 & \text{Стационарность,} \\ \lambda_i \geqslant 0 & & \text{Двойственная допустимость,} \\ \eta_i \geqslant 0 & & \text{Двойственная допустимость,} \\ \xi_i \geqslant 0 & & \text{Прямая допустимость,} \\ y_i(\langle w, x_i\rangle + b) - 1 + \xi_i \geqslant 0 & & \text{Прямая допустимость.}\end{cases}$$

Теперь рассмотрим условия дополняющей нежёсткости $\lambda_i \cdot (1 - y_i(\langle w, x_i\rangle + b) - \xi_i)) = 0$ и $\eta_i \cdot \xi_i = 0$. В силу $\lambda_i + \eta_i = 1$ и $\lambda_i, \eta_i \geqslant 0$ мы получаем $\lambda_i, \eta_i \in [0, 1]$. Тогда для каждого объекта i возможны 3 исхода:

1. **Перефирийный** $\lambda_i = 0, \eta_i = 1$ и отступ $y_i(\langle w, x_i\rangle + b) > 1$;
2. **Опорный-граничный** $0 < \lambda_i, \eta_i < 1$ и отступ $y_i(\langle w, x_i\rangle + b) = 0$;
3. **Опорный-нарушитель** $\lambda_i = 1, \eta_i = 0$ и отступ $y_i(\langle w, x_i\rangle + b) < 1$.

Так как $w = \sum_{i=1}^n \lambda_i y_i x_i$, то в сумму входят только опорные объекты ($\lambda_i > 0$), следовательно, происходит отбор объектов!

Kernel trick. Теперь перейдем к двойственной задаче

$$\begin{aligned}g(\lambda,\eta) &= \inf_{w,b,\xi_i} \mathcal{L}(w,b,\xi,\lambda,\eta) \\ &= \inf_w \left\{\frac{1}{2}\|w\|^2 - \sum_i \lambda_i y_i x_i^\top w\right\} + \inf_b \left\{\sum_i \lambda_i y_i b\right\} + \sum_{i=1}^n \inf_{\xi_i} \{\xi_i - \lambda_i\xi_i - \eta_i\xi_i\} + \sum_i \lambda_i = \\ &= \begin{cases} -\infty & \sum_i \lambda_i y_i \neq 0 \\ -\infty & \exists i\colon \lambda_i + \eta_i \neq 1 \\ -\frac{1}{2}\|\sum_i \lambda_i y_i x_i\|^2 + \sum_i \lambda_i & \text{иначе}\end{cases}\end{aligned}$$

Таким образом, на множестве допустимых λ, η двойственная функция имеет вид

$$g(\lambda, \eta) = -\frac{1}{2} \sum_{i,j=1}^{n} \lambda_i \lambda_j y_i y_j \langle x_i, x_j \rangle$$

Мы получилм, что двойственная функция зависит от объектов только через $\langle x_i, x_j \rangle$. Представим, что мы хотим перейти от признаков x к признакам $\tilde{x} = F(x) \in \mathbb{R}^D$. Тогда в двойственной задаче мы получим зависимость только от $\langle F(x_i), F(x_j) \rangle$. Функцию $K(x, z) = \langle F(x), F(z) \rangle$ называют ядром. Оказывается, что работать с ядрами намного приятнее, чем с $x \mapsto F(x)$. Вместо построения $F : \mathbb{R}^d \to \mathbb{R}^D$ мы строим скалярную функцию $K : \mathbb{R}^d \times \mathbb{R}^d \to \mathbb{R}$.

Пример 5.2: Пример ядра

Допустим, мы хотим обучить полиномиальную модель. Тогда $F(x)$ — вектор всех мономов степени $< k$. На следующем занятии вы узнаете, что подобному преобразованию $F(x)$ соответствует ядро $K(x, z) = (1 + \langle x, z \rangle)^d$.

5.3 Kernel trick

5.3.1 Откуда появляется kernel trick в SVM?

5.4 Kernel trick в LogReg

6 Задачи

7 (Доп. материал) Субдифференциалы негладких выпуклых функций

8 (Доп. материал) Fenchel duality и сопряженные функции